DOI: http://dx.doi.org/10.15260/rbc.v0i0.00

Previsão diária de crimes em Chicago com Prophet e Random Forest: avaliação com origem deslizante, baselines ingênuas e um dashboard aberto

M.H. Massuda[a], J.L. Rybarczyk Filho[a,*]

[a] *Instituto de Biociências de Botucatu, Universidade Estadual Paulista (UNESP), Botucatu (SP), Brasil*
Endereço de e-mail para correspondência: jose.luiz@unesp.b

Recebido em 00/00/0000; Revisado em 00/00/0000; Aceito em 00/00/0000

Resumo
Comparações entre modelos de previsão de séries temporais de crimes costumam usar um único ano de teste, raramente incluem baselines ingênuas e nem sempre colocam os modelos no mesmo horizonte de previsão, o que dificulta saber quanto do desempenho reportado é aprendizado e quanto é regularidade da série. Este trabalho avalia Prophet e Random Forest (RF) na previsão diária de ocorrências em Chicago (2014–2024, 2,75 milhões de registros) com um protocolo de origem deslizante: para nove séries (oito tipos de crime e o total) e sete anos de teste (2018–2024), cada modelo é treinado com os quatro anos anteriores e prevê os 365 dias seguintes sem acesso aos valores reais. O RF é avaliado em modo recursivo, em que as próprias previsões alimentam os lags; os dois modelos são confrontados com baselines ingênuas e comparados pelo teste de Diebold-Mariano. Os dois reduzem o erro do ingênuo sazonal em cerca de 11% na média dos 63 cenários e têm desempenho equivalente, mas em regimes opostos: o Prophet é melhor em anos estáveis (MAE relativo 0,81 contra 0,90) e falha por extrapolação de tendência nos anos de ruptura da pandemia, quando o RF se iguala a uma baseline que repete o nível do ano anterior. A análise descritiva identifica um artefato de horário padrão na base e mostra que o padrão semanal depende do tipo de crime. Dados, código e um dashboard interativo são disponibilizados em repositório aberto.

Palavras-Chave: previsão de crimes; séries temporais; Prophet; Random Forest; avaliação de previsões

Abstract
Comparisons between crime time-series forecasting models usually rely on a single test year, seldom include naive baselines and do not always place the models on the same forecast horizon, making it hard to tell how much of the reported performance is learning and how much is the regularity of the series. We evaluate Prophet and Random Forest (RF) for daily crime counts in Chicago (2014–2024, 2.75 million records) with a rolling-origin protocol: for nine series (eight crime types and the total) and seven test years (2018–2024), each model is trained on the previous four years and forecasts the next 365 days without access to the true values. RF is evaluated recursively, feeding its own forecasts into the lag features; both models are benchmarked against naive baselines and compared with the Diebold-Mariano test. Both reduce the seasonal-naive error by about 11% on average over the 63 scenarios and perform equivalently, but in opposite regimes: Prophet is better in stable years (relative MAE 0.81 vs 0.90) and fails by trend extrapolation in the pandemic disruption years, when RF matches a baseline that repeats the previous year's level. The descriptive analysis identifies a default-time artifact in the database and shows that the weekly pattern depends on crime type. Data, code and an interactive dashboard are released in an open repository.

Keywords: crime forecasting; time series; Prophet; Random Forest; forecast evaluation

1. INTRODUÇÃO

A previsão de ocorrências criminais a partir de registros históricos tornou-se uma ferramenta corrente de planejamento policial, da alocação de efetivo ao mapeamento de áreas de risco [1, 2]. Em grandes centros, o volume de dados abertos permite comparar métodos estatísticos clássicos e algoritmos de aprendizado de máquina, e revisões recentes apontam Random Forest, redes neurais e modelos aditivos como os mais empregados [3, 4]. Chicago é um caso frequente na literatura, pela disponibilidade de uma base pública com todos os registros desde 2001 [5, 6].

Essas comparações, porém, costumam ser feitas em um único período de teste, sem baselines ingênuas que indiquem quanto do erro reportado se deve à regularidade da série, e nem sempre colocam os modelos no mesmo horizonte: um modelo que recebe os valores observados da véspera para prever o dia seguinte resolve uma tarefa muito mais fácil do que um que prevê um ano inteiro de uma vez, e os dois não deveriam ser comparados pelas mesmas métricas [8, 9]. A literatura de avaliação de previsões recomenda múltiplas origens de previsão, baselines e testes estatísticos de diferença de acurácia [8, 9, 15, 16], e comparações em grande escala mostram que, quando o protocolo é controlado, a vantagem dos métodos de aprendizado de máquina sobre os estatísticos frequentemente desaparece [10]. Além disso, atributos derivados da própria série (lags e médias móveis) exigem cuidado para que não incorporem informação do período previsto, uma das causas mais comuns de resultados otimistas e não reprodutíveis em aprendizado de máquina aplicado [7].

Este artigo estende um trabalho de conclusão de curso [11] que desenvolveu um dashboard interativo para análise e previsão de crimes em Chicago. O objetivo é avaliar Prophet [12] e Random Forest [13] na previsão diária de ocorrências com um protocolo de origem deslizante, em nove séries e sete anos de teste, com ambos os modelos no mesmo horizonte de previsão, baselines ingênuas e teste estatístico de diferença de acurácia; examinar como o desempenho relativo varia entre anos estáveis e anos de ruptura, como os da pandemia de COVID-19; e reexaminar afirmações descritivas frequentes sobre a dinâmica

criminal da cidade (tendência, sazonalidade semanal e horária). Dados, código e o dashboard são disponibilizados em repositório aberto.

2. MATERIAIS E MÉTODOS

2.1. Dados

Utilizou-se a base *Crimes – 2001 to Present* do Chicago Data Portal [5], restrita ao período de 1º de janeiro de 2014 a 31 de dezembro de 2024, com 2.751.199 registros após a exclusão de ocorrências sem data ou coordenadas válidas. Cada registro contém data e hora, tipo primário (*Primary Type*), descrição, indicador de prisão, distrito policial e coordenadas geográficas. Para as séries temporais, as ocorrências foram agregadas por dia; dias sem ocorrência recebem contagem zero. Foram analisadas nove séries: o total de crimes e os oito tipos primários mais frequentes com interpretação direta (THEFT, BATTERY, CRIMINAL DAMAGE, ASSAULT, DECEPTIVE PRACTICE, MOTOR VEHICLE THEFT, ROBBERY e BURGLARY). Os dados são distribuídos no repositório em formato Parquet (92 MB), um arquivo por biênio.

2.2. Modelos

Prophet. Modelo aditivo decomponível em tendência, sazonalidades anual e semanal e efeitos de feriados [12]. Utilizou-se o modo de sazonalidade multiplicativo, feriados nacionais dos Estados Unidos e os demais hiperparâmetros padrão (versão 1.2.1). Como Prophet é um modelo de regressão sobre o tempo, a previsão dos 365 dias do ano de teste é feita de uma só vez, sem uso dos valores observados nesse ano.

Random Forest. Regressor com 200 árvores e `random_state` fixo (scikit-learn 1.7.2 [14]). Os atributos são de dois grupos: calendário (dia da semana, dia do mês, dia do ano, mês, trimestre, semana ISO, fim de semana, feriado, estação, início de mês) e histórico (14 lags diários, média móvel de 7 e 30 dias e desvio-padrão móvel de 7 dias). Todos os atributos históricos são calculados a partir da série deslocada em um dia, de modo que o dia t usa apenas valores até $t - 1$. Para prever o ano de teste, o modelo é aplicado de forma recursiva: a previsão do dia t passa a integrar o histórico usado para prever $t + 1$ e assim por diante, sem acesso aos valores reais. Esse é o único modo que coloca o RF na mesma condição do Prophet. Como referência, reporta-se também o modo "um passo à frente", em que os lags são preenchidos com os valores reais dos dias anteriores do ano de teste.

Baselines. Duas previsões ingênuas: (a) a média diária do último ano de treino, repetida para todos os dias do teste; e (b) o ingênuo sazonal, que repete o valor observado 364 dias antes (mesmo dia da semana do ano anterior), recorrendo a 728 dias quando a data cai fora do treino.

2.3. Protocolo de avaliação

Adotou-se avaliação com origem deslizante (*rolling origin*) [9]: para cada ano de teste $T \in \{2018, \ldots, 2024\}$, os modelos são treinados com os quatro anos anteriores ($T - 4$ a $T - 1$) e preveem os 365 dias de T. Com nove séries, obtêm-se 63 cenários. As métricas são o erro absoluto médio (MAE), a raiz do erro quadrático médio (RMSE), o erro percentual absoluto médio (MAPE, calculado apenas nos dias com valor observado maior que zero) e o erro percentual absoluto médio simétrico (sMAPE), que permanece definido quando há zeros [15]. Para comparar séries de magnitudes distintas, o MAE de cada modelo é expresso em relação ao MAE do ingênuo sazonal no mesmo cenário (valores menores que 1 indicam ganho sobre a previsão ingênua). A diferença de acurácia entre Prophet e RF recursivo em cada cenário é testada com o teste de Diebold-Mariano [16], com perda absoluta e variância de longo prazo estimada por Newey-West com sete defasagens.

2.4. Análise descritiva e espacial

Para as afirmações descritivas, calcularam-se os totais anuais, a distribuição por hora do dia (com e sem os registros cujo minuto é :00, para avaliar o artefato de horário padrão), a média diária por dia da semana por tipo de crime e a média diária por mês. Para a análise espacial, aplicou-se DBSCAN [17] com distância geodésica (*haversine*), raio de 200 m e mínimo de 30 pontos às ocorrências de ASSAULT em 2024.

2.5. Software, reprodutibilidade e uso de IA

Todo o código está em repositório público (Python 3.12, pandas 2.3, scikit-learn 1.7.2, Prophet 1.2.1, Streamlit 1.51), com os dados em Parquet, os scripts de experimento e de figuras, e um dashboard Streamlit que permite repetir as previsões com outros tipos de crime, janelas e hiperparâmetros. A implementação do protocolo experimental, a geração de figuras e tabelas e a redação preliminar deste manuscrito foram realizadas com apoio do assistente de IA generativa Claude (Anthropic, modelo Claude Fable 5.1, outubro de 2026), sob supervisão e verificação dos autores, que respondem integralmente pelo conteúdo. A pesquisa utiliza apenas dados públicos e agregados, sem identificação de pessoas, não envolvendo seres humanos como sujeitos.

3. RESULTADOS

3.1. Dinâmica descritiva da criminalidade em Chicago (2014–2024)

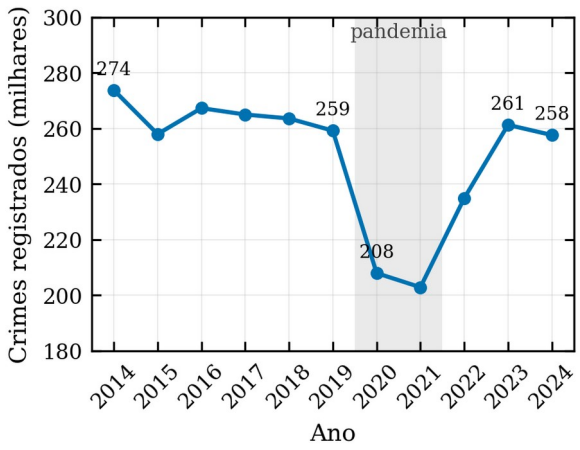


Figura 1. Total anual de crimes registrados em Chicago, 2014–2024. A faixa sombreada marca os anos de pandemia.

A Figura 1 mostra que o total anual oscilou entre 258 e 274 mil registros de 2014 a 2019 (variação de

−5,3% no período), caiu 19,8% em 2020 e voltou ao patamar pré-pandemia em 2023 (261 mil). Não há, portanto, uma tendência de queda acentuada no período, nem um "novo patamar" pós-pandemia.



Figura 2. Distribuição das ocorrências por hora do dia, com todos os registros e excluindo os registros cujo minuto é :00 (34% do total). Os excessos às 0h e às 12h desaparecem na segunda série, indicando horários padrão atribuídos no registro.

A distribuição horária (Fig. 2) tem vale às 5h (27% do pico) e, nos dados brutos, picos às 12h e às 0h. Um terço dos registros tem minuto :00, com concentração nessas duas horas, o que caracteriza um artefato de horário padrão; excluídos esses registros, o período de maior incidência é das 15h às 19h. Esse artefato precisa ser considerado em qualquer análise horária da base.

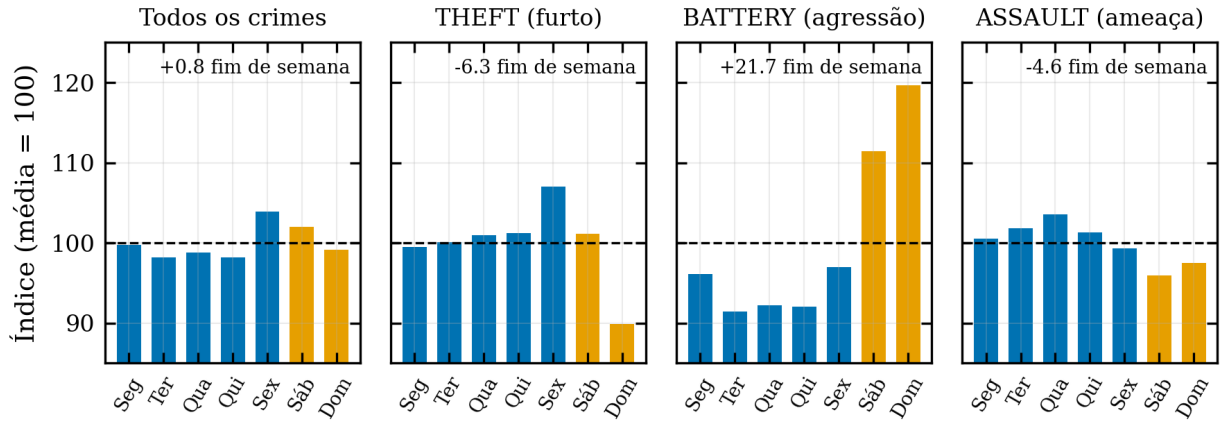


Figura 3. Média diária de ocorrências por dia da semana, em índice (média da série = 100), para o total e para três tipos de crime. Barras em laranja indicam o fim de semana; o número no canto é a diferença média (em pontos) entre fim de semana e dias úteis.

O padrão semanal depende fortemente do tipo de crime (Fig. 3). Para o total, a sexta-feira é o dia de maior incidência e o fim de semana fica na média. A agressão física (BATTERY) tem forte pico no fim de semana (+21,7 pontos), ao passo que o furto (THEFT) e a ameaça (ASSAULT) têm *mínimo* no fim de semana. Uma afirmação genérica de "picos nos fins de semana" vale, portanto, apenas para a violência interpessoal.

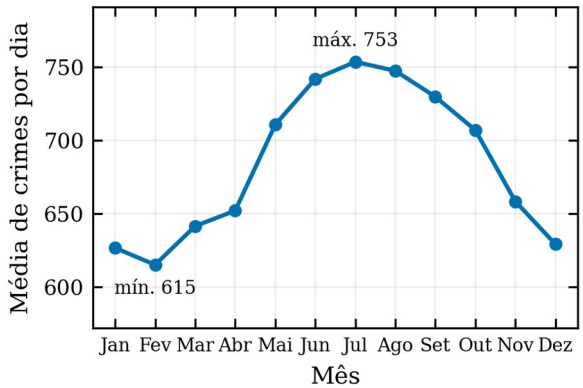


Figura 4. Média diária de ocorrências por mês (todos os crimes, 2014–2024).

A sazonalidade anual é bem definida (Fig. 4): máximo em julho (753 crimes/dia) e mínimo em fevereiro (615), razão de 1,23. Nos feriados nacionais, o total cai 3,5% em relação aos demais dias, mas o efeito varia de sinal por tipo: −6,3% para ASSAULT, −16,0% para THEFT e +9,2% para BATTERY.

3.2. Horizonte de previsão e regime: dois cenários ilustrativos

Tabela 1. Dois cenários ilustrativos. "RF um passo" recebe os valores reais dos dias anteriores do ano de teste; "RF recursivo" prevê o ano inteiro a partir das próprias previsões, na mesma condição do Prophet.

Cenário	Modelo	MAPE (%)	MAE	RMSE
ASSAULT, treino 2014–17, teste 2018	Prophet	12,20	6,59	8,44
	RF recursivo	13,37	7,18	9,04
	RF um passo (referência)	12,19	6,74	8,64

	Média do último ano de treino	15,81	8,72	10,79
	Ingênuo sazonal (t − 364)	17,53	9,52	11,84
THEFT, treino 2017–20, teste 2021	Prophet	54,45	62,88	71,94
	RF recursivo	17,91	20,34	26,03
	RF um passo (referência)	12,52	12,93	17,83
	Média do último ano de treino	21,26	20,17	25,28
	Ingênuo sazonal (t − 364)	30,38	28,58	37,59

A Tabela 1 apresenta dois cenários que antecipam os padrões gerais. No primeiro, um ano estável (ASSAULT em 2018), Prophet e RF recursivo têm erros próximos (MAPE de 12,2% e 13,4%), ambos bem abaixo das baselines (15,8% e 17,5%). O RF um passo à frente, que conhece o valor real da véspera, obtém 12,2%: a diferença para o modo recursivo mede quanto o acesso a valores do período de teste reduz o erro aparente, e mostra por que um modelo de lags avaliado um passo à frente não deve ser comparado a um modelo que prevê o ano inteiro.

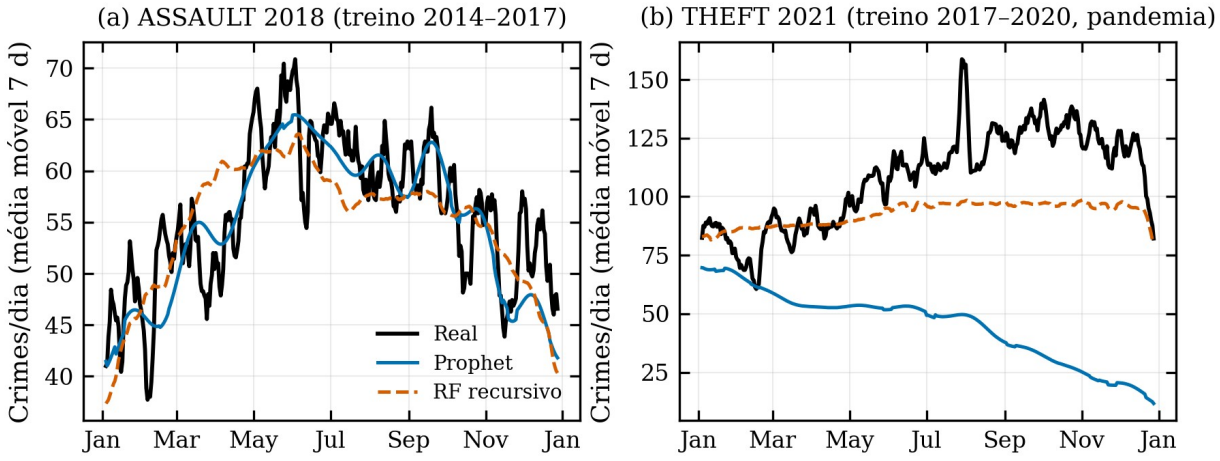


Figura 5. Previsões e valores reais (média móvel de 7 dias) nos dois cenários da Tabela 1. (a) ASSAULT 2018, ano estável; (b) THEFT 2021, ano de ruptura.

No segundo cenário, um ano de ruptura (THEFT em 2021, após a queda de 2020), o Prophet falha (MAPE de 54%), porque extrapola para 2021 a tendência de queda aprendida em 2020, enquanto os furtos se estabilizaram (Fig. 5b). O RF recursivo obtém 17,9%, mas seu MAE (20,34) é praticamente igual ao da baseline que repete a média diária de 2020 (20,17): nesse regime, o que o RF acerta é o nível recente.

3.3. Avaliação com origem deslizante

Tabela 2. Desempenho médio nos 63 cenários (9 séries × 7 anos de teste). MAE relativo = MAE do modelo dividido pelo MAE do ingênuo sazonal no mesmo cenário (média e mediana entre cenários). "Vitórias" conta os cenários em que o modelo teve o menor MAE entre os quatro métodos de previsão multi-passo. O RF um passo à frente é mostrado apenas como referência, pois usa valores reais do período de teste.

Modelo	MAE relativo (média)	MAE relativo (mediana)	sMAPE médio (%)	sMAPE mediano (%)	Vitórias
Prophet	0,89	0,79	23,6	18,7	32
RF recursivo	0,89	0,84	21,3	19,1	23
Média do último ano	0,91	0,91	21,7	20,3	8
Ingênuo sazonal (t − 364)	1,00	1,00	24,6	22,7	0
RF um passo (referência)	0,65	0,67	15,8	13,7	—

Na média dos 63 cenários (Tab. 2), Prophet e RF recursivo têm o mesmo MAE relativo (0,89) e a diferença entre eles e a baseline que repete a média do último ano (0,91) é pequena. Os dois modelos reduzem o erro do ingênuo sazonal em cerca de 11% na média, e 21% (Prophet) e 16% (RF) na mediana. O Prophet é o melhor método em 32 cenários e o RF em 23; em 8 cenários nenhum dos dois supera a média do último ano. O RF um passo à frente, com MAE relativo de 0,65, ilustra quanto o acesso aos valores reais da véspera reduz o erro aparente: essa é a ordem de grandeza da vantagem que a avaliação um passo à frente concede a um modelo de lags.

Tabela 3. MAE relativo ao ingênuo sazonal por ano de teste (média das nove séries) e por regime.

Ano de teste	Prophet	RF recursivo	Média do último ano
2018	0,77	0,95	0,98
2019	0,73	0,91	0,96
2020	0,85	0,80	0,91

2021	1,13	0,95	0,81
2022	0,99	0,89	0,93
2023	0,93	0,82	0,86
2024	0,81	0,91	0,88
Estável (2018–19, 2023–24)	**0,81**	**0,90**	**0,92**
Ruptura (2020–22)	**0,99**	**0,88**	**0,88**

A média esconde dois regimes (Tab. 3). Nos anos estáveis (2018, 2019, 2023 e 2024), o Prophet é claramente o melhor (0,81 contra 0,90 do RF e 0,92 da baseline). Nos anos de ruptura (2020 a 2022), o Prophet perde todo o ganho sobre o ingênuo sazonal (0,99) e chega a ser pior que ele em 2021 (1,13), enquanto o RF recursivo (0,88) fica exatamente no nível da baseline de média do último ano (0,88). Em outras palavras, a robustez do RF em períodos de ruptura equivale à de uma previsão constante no nível recente.

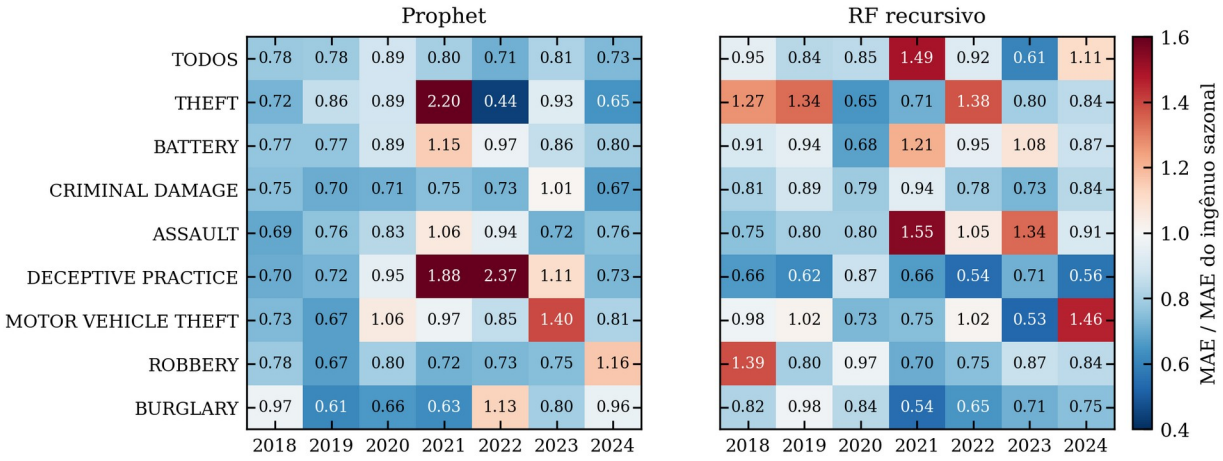


Figura 6. MAE relativo ao ingênuo sazonal (valores menores que 1 indicam ganho) por série e ano de teste, para Prophet (esquerda) e RF recursivo (direita). Vermelho escuro marca falhas graves do Prophet por extrapolação de tendência (THEFT 2021; DECEPTIVE PRACTICE 2021–2022) e do RF por mudança de nível não antecipada (TODOS e ASSAULT 2021; MOTOR VEHICLE THEFT 2024).

A Figura 6 detalha os cenários. As falhas do Prophet concentram-se em séries com mudança de tendência: THEFT em 2021 (2,2 vezes o erro do ingênuo), DECEPTIVE PRACTICE em 2021 e 2022 (1,9 e 2,4 vezes), quando a série de fraudes cresceu abruptamente durante a pandemia [18], e MOTOR VEHICLE THEFT em 2023. O RF, por sua vez, falha quando o nível muda dentro do ano de teste e seus lags recursivos não têm como acompanhar (TODOS e ASSAULT em 2021; MOTOR VEHICLE THEFT em 2024). Para DECEPTIVE PRACTICE e BURGLARY, séries com tendência monotônica forte, o RF é consistentemente melhor; para o total, CRIMINAL DAMAGE, ROBBERY e BATTERY, o Prophet é melhor na maioria dos anos.

Tabela 4. Teste de Diebold-Mariano entre Prophet e RF recursivo (perda absoluta; α = 0,05): número de cenários por modelo favorecido.

Modelo favorecido	Diferença significativa	Não significativa	Total
Prophet	27	10	37
RF recursivo	20	6	26

O teste de Diebold-Mariano (Tab. 4) confirma que a diferença entre os modelos é real na maioria dos cenários, mas em direções opostas: o Prophet é significativamente mais acurado em 27 cenários e o RF em 20. Nenhum dos dois domina; a escolha depende do tipo de crime e do regime da série.

3.4. Análise espacial

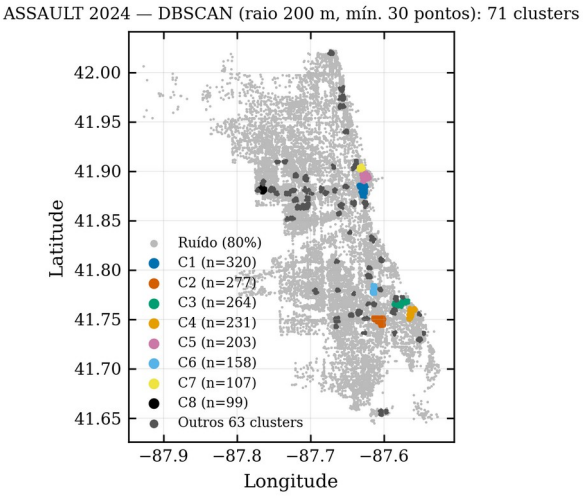


Figura 7. Agrupamentos DBSCAN (raio 200 m, mínimo 30 pontos) das ocorrências de ASSAULT em 2024. Os oito maiores clusters são destacados; 80% dos pontos são classificados como ruído.

A Figura 7 ilustra a componente espacial do dashboard. Com distância geodésica e raio em metros, o DBSCAN identifica 71 agrupamentos densos de ASSAULT em 2024, concentrados no centro (Loop e River North) e em corredores comerciais do sul e do oeste da cidade, com 80% das ocorrências classificadas como ruído difuso. O uso de distância geodésica, em vez de coordenadas padronizadas por eixo, torna o raio de busca interpretável em metros, já que um grau de latitude e um de longitude não têm o mesmo comprimento.

4. DISCUSSÃO

O primeiro resultado é metodológico. Três decisões de protocolo mudam a resposta à pergunta "qual modelo é melhor": o horizonte em que os modelos de lags são avaliados, a presença de baselines ingênuas e o número de origens de previsão. Um Random Forest avaliado um passo à frente tem erro 27% menor do que o mesmo modelo prevendo o ano inteiro de forma recursiva (Tab. 2); comparado a um Prophet que prevê 365 dias de uma vez, ele pareceria claramente superior, quando na mesma condição os dois são equivalentes. Sem baselines, um MAPE de 12% ou 18% não informa se há aprendizado: no cenário THEFT 2021, a baseline de nível recente tem o mesmo erro do RF. E com um único ano de teste, a conclusão depende de o ano ser estável ou de ruptura, como a Tabela 3 mostra. Essas recomendações são as da literatura de avaliação de previsões [8, 9, 15, 16] e da discussão recente sobre reprodutibilidade em aprendizado de máquina aplicado [7, 10]; o que este trabalho acrescenta é a quantificação, para dados criminais, do tamanho de cada efeito. Sugere-se que comparações entre modelos de previsão de crimes declarem explicitamente o horizonte, o modo de atualização dos lags e a forma de cálculo dos atributos móveis, e incluam baselines ingênuas e mais de uma origem de previsão.

O segundo resultado é substantivo. Em 63 cenários, Prophet e Random Forest são equivalentes na média e cada um é melhor em um regime: o Prophet em anos estáveis, em que a sazonalidade semanal e anual explica a maior parte da variação; o RF em anos de ruptura, em que o Prophet extrapola uma tendência que não se sustenta. Esse comportamento é coerente com a estrutura dos modelos: o Prophet é uma regressão sobre o tempo com tendência linear por partes, e seus pontos de mudança são estimados apenas no treino, de modo que uma inflexão em 2020 é projetada para 2021 inteiro; o RF com lags recursivos não extrapola, pois árvores de decisão só devolvem valores vistos no treino, e por isso converge rapidamente para o nível recente, como na Figura 5b. A consequência prática é que a robustez do RF em períodos atípicos não é evidência de que ele capture relações complexas: uma baseline que repete a média do ano anterior tem o mesmo erro (0,88 na Tab. 3). Para uso operacional, isso sugere combinar os modelos ou, de forma mais simples, usar o Prophet com tendência restrita (por exemplo, tendência plana ou saturada) em períodos de instabilidade conhecida, e testar sempre contra a baseline de nível recente. Esses achados convergem com a literatura de competições de previsão, em que métodos estatísticos simples frequentemente igualam ou superam métodos de aprendizado de máquina quando a avaliação é controlada [10].

Quanto à descrição da criminalidade em Chicago, três afirmações frequentes merecem qualificação. A queda de 2014 a 2019 foi de apenas 5%, e o nível de 2023 e 2024 é o mesmo de 2019, de modo que não há "novo patamar" pós-pandemia nos registros. O padrão semanal não é único: a violência interpessoal (BATTERY) concentra-se no fim de semana, mas furto e ameaça são mais frequentes nos dias úteis, com mínimo no fim de semana, e o total é dominado pela sexta-feira. E a distribuição horária da base contém um artefato de horário padrão (12:00 e 00:00) que responde por um terço dos registros; qualquer análise horária ou modelo com granularidade sub-diária precisa tratá-lo, sob pena de identificar "picos" que são decisões de registro e não comportamento criminal. Esse artefato é um exemplo concreto da ressalva, feita por vários autores [19, 20], de que registros policiais medem a atividade de registro tanto quanto a criminalidade.

O estudo tem limitações. Os hiperparâmetros foram fixados em valores padrão razoáveis e não otimizados por série, o que pode penalizar o RF, mais sensível a eles; em contrapartida, a otimização teria de ser feita com validação interna ao treino para não usar informação do período de teste. Apenas uma janela de treino (quatro anos) foi avaliada. A análise é agregada para a cidade; a previsão espaço-temporal em unidades menores, para a qual o DBSCAN aqui serve apenas como ilustração, tem dinâmica própria e maior esparsidade [4, 6]. Por fim, os dados são de crimes registrados, sujeitos a subnotificação diferencial por tipo e região.

5. CONCLUSÕES

Este trabalho avaliou Prophet e Random Forest na previsão diária de crimes em Chicago com um protocolo de origem deslizante, em nove séries e sete anos de teste, com os dois modelos no mesmo horizonte, baselines ingênuas e teste de Diebold-Mariano. Os dois modelos são equivalentes na média e reduzem o erro do ingênuo sazonal em cerca de 11%; o Prophet é superior em anos estáveis e falha por extrapolação de tendência em anos de ruptura, nos quais a vantagem do Random Forest equivale à de uma previsão constante no nível recente. O horizonte de avaliação dos modelos de lags, a presença de baselines e o número de anos de teste mostraram-se decisivos para a conclusão, e devem ser declarados em qualquer comparação do gênero. A análise descritiva qualificou afirmações sobre tendência e padrão semanal e identificou um artefato de registro horário que afeta qualquer análise sub-diária da base. Dados, código, figuras e um dashboard interativo para repetir as previsões com outros parâmetros estão disponíveis em repositório aberto.

Agradecimentos

Os autores agradecem ao Instituto de Biociências de Botucatu da UNESP pelo apoio institucional. Este trabalho deriva do trabalho de conclusão de curso do primeiro autor [11].

Conflito de interesses. Os autores declaram não haver conflito de interesses.

Disponibilidade de dados e código. Dados em Parquet, scripts de experimento (`paper/experimento_rolling.py`), de figuras e de tabelas, e o dashboard Streamlit estão disponíveis em https://github.com/<usuario>/chicago-crime-analytics (licença MIT). Os dados originais são do Chicago Data Portal [5].

Referências Bibliográficas

[1] W.L. Perry; B. McInnis; C.C. Price; S.C. Smith; J.S. Hollywood. *Predictive Policing: The Role of Crime Forecasting in Law Enforcement Operations*. RAND Corporation, Santa Monica, Estados Unidos (2013).

[2] G.O. Mohler; M.B. Short; S. Malinowski; M. Johnson; G.E. Tita; A.L. Bertozzi; P.J. Brantingham. Randomized controlled field trials of predictive policing. *J. Am. Stat. Assoc.* **110**: 1399-1411 (2015).

[3] V. Mandalapu; L. Elluri; P. Vyas; N. Roy. Crime prediction using machine learning and deep learning: a systematic review and future directions. *IEEE Access* **11**: 60153-60170 (2023).

[4] U.M. Butt; S. Letchmunan; F.H. Hassan; M. Ali; A. Baqir; H.H.R. Sherazi. Spatio-temporal crime hotspot detection and prediction: a systematic literature review. *IEEE Access* **8**: 166553-166574 (2020).

[5] City of Chicago. Crimes – 2001 to Present. Chicago Data Portal. Retirado em 03/10/2026, de https://data.cityofchicago.org/Public-Safety/Crimes-2001-to-Present/ijzp-q8t2

[6] C. Catlett; E. Cesario; D. Talia; A. Vinci. Spatio-temporal crime predictions in smart cities: a data-driven approach and experiments. *Pervasive Mob. Comput.* **53**: 62-74 (2019).

[7] S. Kapoor; A. Narayanan. Leakage and the reproducibility crisis in machine-learning-based science. *Patterns* **4**: 100804 (2023).

[8] L.J. Tashman. Out-of-sample tests of forecasting accuracy: an analysis and review. *Int. J. Forecast.* **16**: 437-450 (2000).

[9] C. Bergmeir; J.M. Benítez. On the use of cross-validation for time series predictor evaluation. *Inf. Sci.* **191**: 192-213 (2012).

[10] S. Makridakis; E. Spiliotis; V. Assimakopoulos. Statistical and machine learning forecasting methods: concerns and ways forward. *PLoS ONE* **13**: e0194889 (2018).

[11] M.H. Massuda. Inteligência artificial na segurança urbana: uma análise preditiva dos crimes em Chicago. *Trabalho de Conclusão de Curso (Bacharelado em Física Médica)*, Instituto de Biociências de Botucatu, Universidade Estadual Paulista (2025).

[12] S.J. Taylor; B. Letham. Forecasting at scale. *Am. Stat.* **72**: 37-45 (2018).

[13] L. Breiman. Random forests. *Mach. Learn.* **45**: 5-32 (2001).

[14] F. Pedregosa; G. Varoquaux; A. Gramfort; V. Michel; B. Thirion; O. Grisel; M. Blondel; P. Prettenhofer; R. Weiss; V. Dubourg; J. Vanderplas; A. Passos; D. Cournapeau; M. Brucher; M. Perrot; É. Duchesnay. Scikit-learn: machine learning in Python. *J. Mach. Learn. Res.* **12**: 2825-2830 (2011).

[15] R.J. Hyndman; A.B. Koehler. Another look at measures of forecast accuracy. *Int. J. Forecast.* **22**: 679-688 (2006).

[16] F.X. Diebold; R.S. Mariano. Comparing predictive accuracy. *J. Bus. Econ. Stat.* **13**: 253-263 (1995).

[17] M. Ester; H.-P. Kriegel; J. Sander; X. Xu. A density-based algorithm for discovering clusters in large spatial databases with noise. *Anais da Second International Conference on Knowledge Discovery and Data Mining (KDD-96)*, 226-231 (1996).

[18] M.P.J. Ashby. Initial evidence on the relationship between the coronavirus pandemic and crime in the United States. *Crime Sci.* **9**: 6 (2020).

[19] K. Lum; W. Isaac. To predict and serve? *Significance* **13**: 14-19 (2016).

[20] S. Chainey; L. Tompson; S. Uhlig. The utility of hotspot mapping for predicting spatial patterns of crime. *Secur. J.* **21**: 4-28 (2008).