UNIVERSIDADE ESTADUAL PAULISTA "JÚLIO DE MESQUITA FILHO"
INSTITUTO DE BIOCIÊNCIAS DE BOTUCATU

MATHEUS HENRIQUE MASSUDA

Inteligência Artificial na Segurança Urbana: Uma Análise Preditiva dos Crimes em Chicago

Botucatu

2025

MATHEUS HENRIQUE MASSUDA

Inteligência Artificial na Segurança Urbana: Uma Análise Preditiva dos Crimes em Chicago

Trabalho de conclusão de curso apresentada ao Instituto de Biociências de Botucatu - UNESP, como parte dos requisitos necessários para obtenção do título de Bacharel em Física Médica.

Orientador: Prof. Dr. José Luiz Rybarczyk Filho

Botucatu

2025

M422i

Massuda, Matheus Henrique
Inteligência Artificial na Segurança Urbana: Uma Análise Preditiva dos Crimes em Chicago / Matheus Henrique Massuda. -- Botucatu, 2025
50 p. : il., tabs.

Trabalho de conclusão de curso (Bacharelado - Física Médica) - Universidade Estadual Paulista (UNESP), Instituto de Biociências, Botucatu
Orientador: José Luiz Rybarczyk Filho

1. Inteligência Artificial. 2. Ciência de Dados. 3. Predição de Dados. 4. Segurança Urbana. 5. Predição de Crimes. I. Título.

Sistema de geração automática de fichas catalográficas da Unesp. Dados fornecidos pelo autor(a).

Aos meus pais, fonte de apoio e confiança durante toda essa jornada.

Agradecimentos

Agradeço à UNESP e ao Instituto de Biociências de Botucatu, pela infraestrutura e suporte técnico que possibilitaram esta pesquisa.

Ao meu orientador, Prof. Dr. José Luiz Rybarczyk Filho, pelas orientações dentro e fora do ambiente acadêmico e pelos valiosos aprendizados sobre inteligência artificial e análise de dados, que foram cruciais para o desenvolvimento deste trabalho.

Aos excelentes professores da Escola Integrada Educativa, em especial ao Prof. Adriano, à Prof.ª Bruna, à Prof.ª Edna, ao Prof. Fernando, ao Prof. Fabrício, ao Prof. Gustavo, à Prof.ª Regina e ao Prof. Sérgio, que, desde o período escolar, não só me transmitiram conhecimentos, mas também valiosos conselhos e lições sobre as experiências da vida.

Aos colegas de sala e de laboratório, pelo compartilhamento de experiências e pelo ambiente colaborativo durante o tempo que passamos juntos.

Aos meus pais, por todo o apoio durante a graduação, possibilitando que eu me dedicasse integralmente à faculdade.

A todos que passaram pela minha vida, contribuindo de alguma forma, positiva ou negativamente, para a construção de quem sou hoje, meus sinceros agradecimentos.

"Esvazie sua mente, seja sem forma, sem formato, como a água.
A água pode fluir suavemente ou pode colidir com força.
Seja água, meu amigo."
(Bruce Lee)

Resumo

Este trabalho investiga a aplicação de técnicas de Inteligência Artificial e Ciência de Dados na segurança pública, focando na previsão de padrões criminais na cidade de Chicago. Foram utilizados dados abertos do portal de criminalidade local, estudando o período de 2001 a 2023, com ênfase na análise preditiva de crimes do tipo "assalto" entre 2014 e 2018. A metodologia incluiu um pré-processamento rigoroso dos dados, análise estatística e exploratória temporal e espacial, e a implementação de dois modelos preditivos: *Prophet* (especializado em séries temporais) e *Random Forest* (baseado em *ensemble learning*). Os modelos foram integrados a um *dashboard* interativo desenvolvido em Streamlit, permitindo visualizações geoespaciais, análises estatísticas e a exploração de tendências criminais. Os resultados obtidos entre os modelos são próximos, mas indicam que o Random Forest obteve um desempenho melhor em todas as métricas utilizadas, em especial em termos de erro percentual (MAPE = 10,51%), ao passo que o Prophet (MAPE = 12,27%), com base nos parâmetros utilizados. Além disso, em situações atípicas com quebras de padrões e tendências, como a pandemia da Covid 19, evidenciou-se uma grande diferença no desempenho dos modelos, como expressa o erro percentual do *Prophet* (MAPE = 54,44%) e o do *Random Forest* (MAPE = 10,32%). Conclui-se que a integração de IA e a visualização interativa do *dashboard* constituem uma ferramenta promissora para apoiar a tomada de decisão em segurança urbana, com potencial de replicação em outros contextos metropolitanos.

Abstract

This study investigates the application of Artificial Intelligence and Data Science techniques in public safety, focusing on predicting crime patterns in the city of Chicago. The research utilized open data from the local crime portal, examining the period from 2001 to 2023, with emphasis on predictive analysis of "assault" crimes between 2014 and 2018. The methodology included rigorous data preprocessing, temporal and spatial exploratory statistical analysis, and the implementation of two predictive models: Prophet (specialized in time series) and Random Forest (based on ensemble learning). The models were integrated into an interactive dashboard developed in Streamlit, enabling geospatial visualizations, statistical analyses, and exploration of crime trends. The results obtained from both models were comparable, but indicated that Random Forest achieved superior performance across all evaluated metrics, particularly in terms of percentage error (MAPE = 10.51%), while Prophet recorded MAPE = 12.27% based on the parameters employed. Furthermore, in atypical situations involving pattern disruptions and trend breaks, such as the COVID-19 pandemic, a significant performance disparity between the models was evidenced, as expressed by Prophet's percentage error (MAPE = 54.44%) compared to Random Forest (MAPE = 10.32%). It is concluded that the integration of AI and interactive dashboard visualization constitutes a promising tool for supporting decision-making in urban security, with potential for replication in other metropolitan contexts.

Lista de figuras

Figura 1 – Percentual populacional por idade e sexo na Cidade de Chicago - Fonte: U.S. Census Bureau (2023) 21

Figura 2 – Distribuição das etnias e raças em Chicago - Fonte: U.S. Census Bureau (2023) 21

Figura 3 – Índice de pobreza no público infantil e idoso de Chicago - Fonte: U.S. Census Bureau (2023) 21

Figura 4 – Fluxo metodológico adotado no desenvolvimento do trabalho. Fonte: próprio autor 28

Figura 5 – Evolução anual do número total de crimes em Chicago (2001-2023). Fonte: próprio autor. 35

Figura 6 – Representação dos tipos de crimes que foram reportados em Chicago (2001-2023). Fonte: próprio autor. 36

Figura 7 – Contagem do número de crimes reportados conforme as horas do dia, evidenciando o comportamento urbano de Chicago (2001-2023). Fonte: próprio autor. 37

Figura 8 – Apresentação de 2 gráficos sobre análises exploratórias do ano de 2014 até 2018, para as ocorrências de assaltos. Seguindo a ordem da esquerda para a direita, a primeira indica a série original, no caso a distribuição de ocorrências; a segunda demonstra uma análise das ocorrências nos dias da semana, através de *boxplots*. Fonte: próprio autor. 38

Figura 9 – A imagem representa uma parte do *dashboard* construído, neste caso é a parte de análise estatística e temporal dos dados. Fonte: próprio autor. 38

Figura 10 – Apresentação da *interface* interativa com os modelos preditivos *Random Forest* e *Prophet* Fonte: próprio autor. 39

Figura 11 – A figura representa 4 gráficos indicando informações do ano teste (2018). De cima para baixo, a primeira demonstra as tendências dos crimes, no caso é uma tendência crescente; a segunda indica a variação da distribuição de crimes, aumentando ou diminuindo, com a influência dos feriados; a terceira, é uma análise percentual dos crimes conforme os dias; por último, também temos uma análise percentual da distribuição de crimes do dia 1 de Janeiro de 2018 até 1 de Janeiro de 2019. Fonte: próprio autor. 40
Figura 12 – Imagem representativa do *dashboard* utilizando a ferramente de análise espacial para visualizar *hotspots* e distribuições das ocorrências conforme a localização. Fonte: próprio autor 41
Figura 13 – *Interface* inicial do *dashboard*, representando as 4 ferramentas de análise. Fonte: próprio autor 42
Figura 14 – Comparação do desempenho preditivo entre Random Forest e Prophet para crimes de assalto em Chicago (2014-2018). Fonte: próprio autor. . 42
Figura 15 – Resultados da predição de crimes de furto, com o modelo *Prophet*, durante a pandemia da Covid 19. Dados de treino de 2017 a 2020, e ano de teste 2021. Fonte: próprio autor. 43
Figura 16 – Resultados da predição de crimes de furto, com o modelo *Random Forest*, durante a pandemia da Covid 19. Dados de treino de 2017 a 2020, e ano de teste 2021. Fonte: próprio autor. 44

Lista de tabelas

Tabela 1 – Resumo dos Componentes Temporais Identificados 34
Tabela 2 – Padrões Horários de Criminalidade em Chicago (2001-2023) 37
Tabela 3 – Desempenho comparativo dos modelos preditivos 43
Tabela 4 – Desempenho comparativo dos modelos preditivos em situação atípica . 44

Lista de abreviaturas e siglas

IA	Inteligência Artificial
ML	*Machine Learning* (Aprendizado de Máquina)
MAPE	*Mean Absolute Percentage Error* (Erro Percentual Absoluto Médio)
MAE	*Mean Absolute Error* (Erro Absoluto Médio)
MSE	*Mean Squared Error* (Erro Quadrático Médio)
RMSE	*Root Mean Squared Error* (Raiz do Erro Quadrático Médio)
LSTM	*Long Short-Term Memory* (Memória de Longo e Curto Prazo)
ARIMA	*AutoRegressive Integrated Moving Average* (Média Móvel Integrada Autoregressiva)
RF	*Random Forest* (Floresta Aleatória)
DBSCAN	*Density-Based Spatial Clustering of Applications with Noise*
CCTV	*Closed-Circuit Television* (Circuito Fechado de Televisão)
FBI	*Federal Bureau of Investigation*
RQA	*Recurrence Quantification Analysis* (Análise de Quantificação de Recorrência)
FFT	*Fast Fourier Transform* (Transformada Rápida de Fourier)
PCA	*Principal Component Analysis* (Análise de Componentes Principais)
SVM	*Support Vector Machine* (Máquina de Vetores de Suporte)
CLEAR	*Citizen Law Enforcement Analysis and Reporting*
CompStat	*Computer Statistics* (Estatística Computacional)
CPU	*Central Processing Unit* (Unidade Central de Processamento)
HDD	*Hard Disk Drive* (Disco Rígido)
API	*Application Programming Interface*(Interface de Programação de Aplicações)

Sumário

1 INTRODUÇÃO 13

1.1 O que é a Criminologia 13

1.1.1 Criminologia na era da informática 13

1.1.2 O uso de inteligência artificial na criminologia 14

1.2 Modelos Computacionais para Análise de Dados 14

1.2.1 Abordagens Temporais 14

1.2.2 Abordagens de Classificação 16

1.2.3 Abordagens Espaciais com DBSCAN (*Density-Based Spatial Clustering*) 18

1.3 Segurança Urbana em Chicago: Características, Dados e Desafios . . . 20

1.3.1 Fatores Sociais e Criminais 21

1.3.2 Panorama Criminal e Disponibilidade de Dados 22

1.4 Chicago como Laboratório de Inovação em Segurança Pública 22

1.4.1 Trajetória Histórica 23

1.4.2 Desafios para Análise Preditiva 23

2 Justificativa 25

3 OBJETIVOS 27

4 MATERIAIS E MÉTODOS 28

4.1 Workflow de Pesquisa 28

4.1.1 Análise Estatística Descritiva 29

4.1.2 Análise Exploratória de Série Temporal 29

4.1.3 Modelagem Preditiva 30

4.2 Base de Dados 30

4.3 Pré-processamento de dados e criação dos modelos 31

4.3.1 Ferramentas e Ambiente Computacional 31

4.3.2 Protocolo de Limpeza e Transformação 33

4.3.3 Protocolo dos Modelos Preditivos 33

4.4 Construção do Dashboard 34

5 RESULTADOS E ANÁLISES 35
5.1 Contextualização Histórica (2001-2023) 35
5.1.1 Evolução Temporal de Longo Prazo 35
5.1.2 Tipos de crimes mais reportados 36
5.1.3 Análise do horário das ocorrências de Chicago 36
5.2 Resultados da Análise Exploratória de Série Temporal 37
5.3 Análises preditivas obtidas 38
5.4 Exploração dos dados por meio da localização 41
5.5 Visualização da interface interativa e os códigos envolvidos 41
5.6 Comparação do modelo Random Forest e Prophet 42
5.6.1 Comparação em situações atípicas 43
5.7 DISCUSSÃO 45
5.7.1 Avaliação da interface interativa 45
5.7.2 Limitações do estudo 45

6 CONCLUSÃO 46

Referências[1] 47

[1] De acordo com a Associação Brasileira de Normas Técnicas. NBR 6023.

1 INTRODUÇÃO

1.1 O que é a Criminologia

A criminologia é a ciência que estuda o crime, o criminoso, a vítima e o controle social do delito. Diferente da criminalística, que se concentra na prova material do fato, a criminologia adota uma abordagem teórica e empírica, investigando as causas, a natureza, a extensão e as formas de prevenção da criminalidade. Surgiu como disciplina autônoma no final do século XIX, no seio da escola positivista, que buscava aplicar métodos científicos ao estudo do comportamento criminoso.

Sua consolidação é marcada pela publicação da obra "*Criminologia*" (1885), do jurista italiano Raffaele Garofalo, que cunhou o próprio termo. Paralelamente, os trabalhos de Cesare Lombroso, com sua teoria do "criminoso nato", e de Enrico Ferri, que enfatizou fatores sociais e antropológicos, foram fundamentais para estabelecer a criminologia como um campo de estudo distinto do Direito Penal. Estes pioneiros deslocaram o foco do ato criminoso para a pessoa do criminoso e seu contexto, inaugurando uma análise interdisciplinar que integra saberes da sociologia, psicologia e antropologia (BURNEY; PEMBERTON, 2013)

1.1.1 Criminologia na era da informática

A Era da Informática transformou profundamente a criminologia, expandindo seu foco para além do crime tradicional. Esta transformação opera em três dimensões principais:

- **Novo Objeto de Estudo:** Surgem os cibercrimes (fraudes, hacking) e crimes tradicionais potencializados pela tecnologia (como bullying digital), exigindo novas teorias e formas de investigação;
- **Novas Metodologias:** A ciência de dados permite a análise de grandes volumes de informação (Big Data) para identificar padrões criminais, redes complexas e realizar o policiamento preditivo;
- **Novos Desafios:** Ferramentas como vigilância massiva e inteligência artificial criam um dilema entre segurança e direitos fundamentais (privacidade, não discriminação), arriscando a amplificação de vieses.

Em essência, a criminologia na era digital precisa equilibrar o uso de ferramentas tecnológicas para eficiência e segurança com a crítica ética necessária para proteger a liberdade e a justiça social (SHMATKO, 2020; GARLAND, 2012).

1.1.2 O uso de inteligência artificial na criminologia

A inteligência artificial (IA) consolida-se como uma tecnologia transformadora em diversas áreas do conhecimento, com aplicações promissoras na criminologia. (PERRY et al., 2013). Ao analisar suas possíveis aplicações neste domínio, destacam-se:

- **Análise preditiva e ciência de dados**: Utilização de algoritmos para a identificação de padrões temporais e espaciais, permitindo a detecção de *hotspots* criminais e a previsão de tendências delitivas (PERRY et al., 2013; BACHNER, 2013);
- **Reconhecimento de padrões**: Aplicação de redes neurais convolucionais (CNNs) para análise forense de imagens de CCTV, reconhecimento facial e identificação de evidências digitais (AKBULUT et al., 2018);
- **Otimização operacional**: Implementação de sistemas inteligentes para alocação estratégica de recursos policiais baseada em modelos preditivos (BACHNER, 2013);
- **Gestão inteligente de dados**: Estruturação e organização de bancos de dados criminais em plataformas de dados abertos, permitindo análises retrospectivas e prospectivas (BACHNER, 2013).

1.2 Modelos Computacionais para Análise de Dados

1.2.1 Abordagens Temporais

LSTM (*Long Short-Term Memory*)

O LSTM é um tipo especial de rede neural recorrente projetada para reconhecer padrões em sequências temporais. Sua principal vantagem é a capacidade de "memorizar" informações relevantes por longos períodos, sendo ideal para a análise de dados que evoluem ao longo do tempo, como séries criminais.

Em relação às aplicações em dados criminais, percebe-se a sua capacidade de identificar padrões espaço-temporais de criminalidade; prever ocorrências futuras conforme

as tendências do passado; e analisar as dependências temporais complexas em grandes volumes de dados.

Conforme (MANDALAPU et al., 2023), o LSTM se destaca em problemas com grandes volumes de dados e relações temporais complexas, típicas de bancos de dados criminais. No estudo de (SAFAT; ASGHAR; GILLANI, 2021), o modelo foi aplicado com sucesso às bases de Chicago e Los Angeles, seguindo uma metodologia rigorosa:

1. **Preparação dos dados**: Limpeza e tratamento de valores ausentes, garantindo a qualidade dos dados temporais;
2. **Validação temporal**: Teste de estacionariedade (Dickey-Fuller) para verificação de tendências e sazonalidades;
3. **Treinamento**: Divisão 70% treino / 30% teste com configuração de hiperparâmetros (40 epochs, batch size 33 para Chicago);
4. **Avaliação**: Métricas como RMSE e MAE para quantificação do desempenho preditivo.

Safat e colaboradores (MANDALAPU et al., 2023) apresentam os seguintes resultados para cada conjunto de dados: Para os dados de Chicago, temos RMSE de 12,66 e MAE de 11,70, capturando variações intensas em padrões diários/semanais; para Los Angeles: RMSE de 8,78 e MAE de 6,0, com padrões mais estáveis e queda acentuada nos anos recentes.

Embora seja eficaz para capturar padrões não-lineares em grandes conjuntos de dados, o LSTM requer um significativo poder computacional e depende criticamente da qualidade do pré-processamento dos dados. No contexto de Chicago, onde os padrões criminais exibem complexas variações temporais, o LSTM se mostra particularmente promissor, embora demande recursos computacionais substanciais.

ARIMA (*AutoRegressive Integrated Moving Average*)

Diferentemente do modelo LSTM, o ARIMA (AutoRegressive Integrated Moving Average) é uma abordagem estatística clássica para a análise de séries temporais, baseada em componentes autoregressivos e em médias móveis. Ademais, o ARIMA depende criticamente de um rigoroso pré-processamento dos dados para garantir a validade das inferências (MANDALAPU et al., 2023; BUTT et al., 2020).

A aplicação do ARIMA exige que a série seja estacionária, o que requer a utilização de testes estatísticos, como o teste de Dickey-Fuller (DICKEY; AND, 1979), para verificar essa condição essencial. Além disso, o desempenho do modelo depende da correta especificação dos parâmetros (p, d, q), que representam, respectivamente, a ordem do componente autoregressivo, o grau de diferenciação necessário para tornar a série estacionária e a ordem do componente de médias móveis. Por fim, vale destacar que o ARIMA apresenta vantagem computacional quando comparado a modelos de *deep learning*, sendo particularmente indicado para conjuntos de dados menores, nos quais sua implementação é eficiente e adequada.

Diante disso, ao analisar suas aplicações na segurança pública, conforme (CATLETT et al., 2019), o ARIMA demonstra particular eficácia em contextos de menor escala, não sendo eficiente em situações com um grande conjunto de dados, mas sim em cidades de pequeno porte ou em bases de dados altamente filtradas. A metodologia padrão envolve a divisão espacial dos dados em regiões distintas, possibilitando a geração de séries temporais independentes para cada área. Após isso, há o treinamento dos modelos ARIMA específicos para cada região e, ao fim, a validação dos resultados por meio da comparação com dados reais.

Em estudos comparativos apresentados em (GORR; OLLIGSCHLAEGER; THOMPSON, 2003; WANG et al., 2016), o ARIMA apresentou menor Erro Absoluto Médio (MEA) quando comparado a algoritmos como *Random Forest*, *REPTree* e*ZeroR*, demonstrando boa capacidade de aproximação quantitativa nos volumes gerais de criminalidade ao longo do tempo. Entretanto, sua principal limitação reside no fato de não diferenciar entre tipos distintos de crimes, atuando apenas sobre a série agregada de ocorrências.

Portanto, o ARIMA é considerado uma ferramenta robusta para previsão temporal de criminalidade, especialmente em cenários com restrições computacionais ou bases de dados limitadas, desde que respeitados seus pressupostos estatísticos fundamentais.

1.2.2 Abordagens de Classificação

Random Forest

O *Random Forest* é um algoritmo de *ensemble* que combina múltiplas árvores de decisão, oferecendo robustez contra *overfitting* e alta capacidade de generalização. No

contexto criminal, esse modelo tem sido amplamente utilizado para a classificação de tipos de crime a partir de características temporais e espaciais, para a identificação de fatores de risco associados a diferentes modalidades delitivas e para a previsão da probabilidade de ocorrência de eventos criminais por categoria. Sua estrutura, composta por diversas árvores independentes que votam na predição final, permite ao modelo capturar padrões complexos nos dados, mesmo quando estes apresentam alta variabilidade.

Conforme demonstrado no estudo de (WANG et al., 2016), o *Random Forest* tem se destacado em avaliações comparativas com outros algoritmos preditivos aplicados à segurança pública. Dentre suas principais vantagens, destaca-se a capacidade de lidar com relações não lineares complexas, uma característica recorrente em bases criminais heterogêneas. Além disso, o modelo oferece medidas de importância das variáveis, o que possibilita identificar quais fatores têm maior peso na dinâmica criminal, um aspecto fundamental para a formulação de políticas públicas. Soma-se a isso sua robustez frente à presença de *outliers* e à ocorrência de dados ausentes, condições comuns em registros policiais. Também apresenta alta performance em problemas de classificação multiclasse, permitindo diferenciar de forma eficiente entre diferentes tipos de delitos.

A superioridade do *Random Forest* em relação a algoritmos como Regressão Linear, SVM e Redes Neurais convencionais foi evidenciada em múltiplos cenários de previsão criminal, com ganhos de acurácia que variaram entre 6% e 15%, dependendo do contexto urbano analisado. Esses resultados reforçam sua adequação como ferramenta de suporte à análise e previsão de criminalidade, sobretudo em ambientes complexos, onde múltiplos fatores interagem de forma não determinística.

Prophet

Desenvolvido pelo *Facebook* (empresa Meta), o *Prophet* é um procedimento de previsão baseado em um modelo aditivo, especialmente projetado para séries temporais com padrões sazonais fortes e múltiplas sazonalidades. Diferentemente do modelo ARIMA, que requer vasto conhecimento estatístico para a parametrização, o *Prophet* foi projetado para ser robusto e acessível, automatizando grande parte do processo de modelagem temporal. Além disso, este estudo (DE; KAUR; BEHERA, 2022) comparou o desempenho entre os modelos Prophet, LSTM e redes neurais, evidenciando um melhor desempenho

por parte do *Prophet* e do LSTM, por meio das seguintes métricas: Erro Quadrático Médio da Raiz (*Root Mean Square Error* - RMSE) e Correlação de Spearman (*Spearman correlation*).

O *Prophet* decompõe a série temporal em três componentes principais. A tendência representa o comportamento de crescimento ou decaimento não periódico da série, incluindo pontos de mudança ao longo do tempo. A sazonalidade modela variações periódicas, como padrões diários, semanais ou anuais que se repetem sistematicamente. Por fim, o modelo incorpora também efeitos associados a feriados ou eventos específicos, permitindo capturar desvios pontuais que impactam significativamente a série.

No contexto da análise de dados criminais, o *Prophet* apresenta vantagens relevantes. O modelo mantém bom desempenho mesmo na presença de dados faltantes, condição comum em bases policiais. Além disso, sua capacidade de capturar múltiplas sazonalidades possibilita identificar variações semanais (como diferenças entre dias úteis e finais de semana) e anuais (como variações entre estações do ano), características frequentemente presentes em dinâmicas criminais. Sua estrutura de decomposição facilita a interpretabilidade dos resultados, permitindo compreender separadamente tendência, sazonalidade e eventos pontuais, e seu tratamento robusto a *outliers* reduz o impacto de valores atípicos que poderiam distorcer previsões.

Portanto, o modelo *Prophet* é um procedimento promissor para a previsão de tendências, baseado em um modelo aditivo que lida com a complexidade das séries temporais, conforme o livro "*An Introduction to Categorical Data Analysis*" (AGRESTI, 2018). Ele é capaz de incorporar e ajustar tendências não lineares, sazonalidade anual, semanal e/ou diária, e efeitos de feriados. Essa estrutura permite a análise de padrões, como a sazonalidade observada nos dados de crimes em Chicago (picos no verão e baixos no inverno) (FENG et al., 2019). Sendo assim, garantindo um equilíbrio entre performance preditiva, interpretabilidade e facilidade de implementação, que são valiosos para a tomada de decisão em segurança pública.

1.2.3 Abordagens Espaciais com DBSCAN (*Density-Based Spatial Clustering*)

O DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) é um algoritmo de clusterização baseado em densidade que se mostra particularmente adequado

para a análise espacial da criminalidade. Diferente de algoritmos baseados em partições, como *K-means*, o *DBSCAN* não requer a pré-definição do número de *clusters* e é capaz de identificar formatos arbitrários de aglomerados, característica essencial para padrões criminais urbanos que frequentemente assumem geometrias irregulares, como apresenta o seguinte artigo (ESTER; SANDER; XU, 1996).

Portanto, em relação às aplicações em análise criminal, o estudo feito por (ESTER et al., 1996) apresenta aplicações e características do *DBSCAN*, ao passo que revela vantagens significativas para a análise de dados geoespaciais, o que o torna particularmente útil em estudos de criminalidade. O algoritmo permite a detecção de *hotspots* naturais ao identificar aglomerados de crimes com base exclusivamente na densidade espacial, sem a necessidade de impor formatos ou estruturas pré-definidas aos agrupamentos. Além disso, o *DBSCAN* é robusto a *outliers*, classificando automaticamente pontos isolados como ruído e filtrando ocorrências esparsas que não representam padrões relevantes. Outra característica relevante é sua adaptabilidade a distintas escalas geográficas, podendo ser aplicado tanto em níveis locais, como a análise de quadras, quanto em regiões mais amplas, como bairros ou áreas metropolitanas, preservando a consistência das detecções, como demonstrado no estudo (CHAINEY; TOMPSON; UHLIG, 2008).

Diante disso, ao avaliar a implementação do DBSCAN no contexto de dados criminais em Chicago, isso envolve, além de um pré-processamento de dados bem feito, a formatação das coordenadas e o tratamento de valores faltantes. Além disso, é necessário selecionar o raio de vizinhança para definir a densidade do agrupamento, o número mínimo de pontos que formam um cluster e comparar as divisões estabelecidas com as divisões administrativas do local já existentes.

Vantagens Comparativas, Limitações e Considerações Práticas

Estudos analisados, incluindo (WANG et al., 2016), demonstram que o DBSCAN supera abordagens tradicionais, uma vez que a precisão na detecção, isto é, a captura de padrões espaciais, é realizada de forma autêntica e diretamente a partir da distribuição dos dados. Além disso, os parâmetros utilizados, no caso o ϵ e `min_samples`, possuem interpretação geográfica intuitiva, o que facilita sua aplicação prática. Soma-se a isso a sua eficiência computacional, tornando-o adequado para extensas bases urbanas.

No entanto, apesar dessas vantagens apresentadas, o DBSCAN apresenta algumas limitações importantes que devem ser consideradas na aplicação a dados criminais. A escolha apropriada dos parâmetros ϵ e $min_samples$ é crítica e depende do contexto espacial analisado, podendo influenciar diretamente a formação dos aglomerados. Além disso, o algoritmo apresenta desempenho reduzido quando os dados exibem variações significativas de densidade entre diferentes regiões da cidade, o que pode levar à subdetecção ou superdetecção de *hotspots*. Por essa razão, é necessária uma etapa cuidadosa de calibração e validação dos parâmetros para cada conjunto de dados específico, garantindo que as estruturas espaciais identificadas representem padrões reais e não artefatos metodológicos. Portanto, observou-se que, para o estudo de padrões espaciais de criminalidade em Chicago, o DBSCAN configura-se como uma ferramenta adequada e eficaz, permitindo a identificação objetiva de *hotspots* com base na distribuição real dos dados, sem as suposições restritivas de normalidade espacial ou de formatos pré-definidos de agrupamento.

1.3 Segurança Urbana em Chicago: Características, Dados e Desafios

Conforme o pesquisador (BUONANNO, 2003), percebeu-se a importância de conhecer os conceitos sociais, culturais e demográficos de determinado local para entender a criminalidade da região, como fatores econômicos, educação, densidade populacional, taxa de natalidade e mortalidade, por exemplo, conforme será apresentado na figura 1, na figura 2 e, por último, na figura 3.

Algumas informações demográficas atuais de Chicago:

- **Distribuição da população por idade e sexo:**

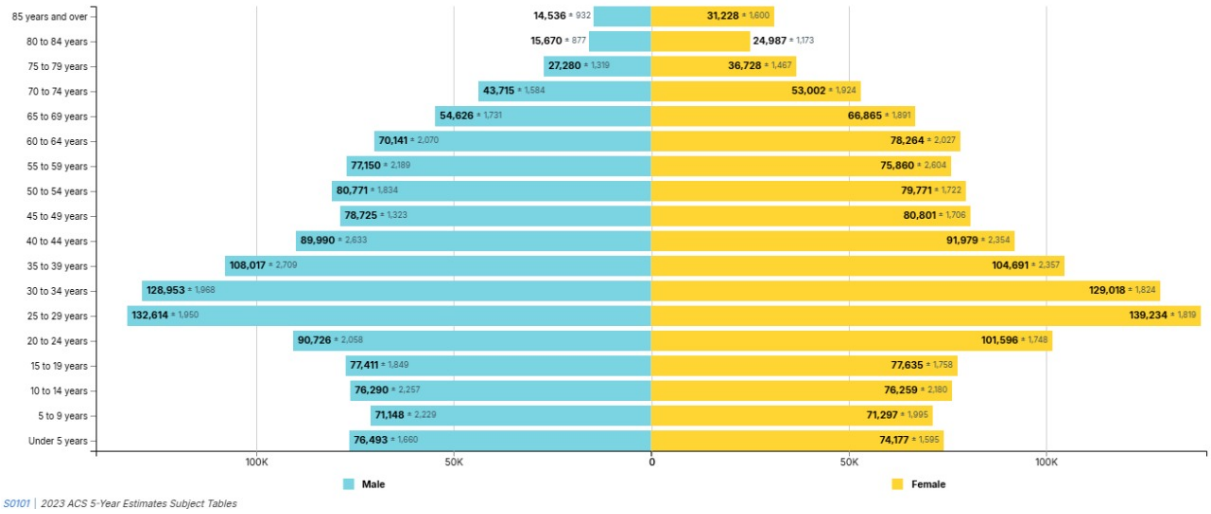


Figura 1 – Percentual populacional por idade e sexo na Cidade de Chicago - Fonte: U.S. Census Bureau (2023)

- **Diversidade étnico-racial em Chicago:**

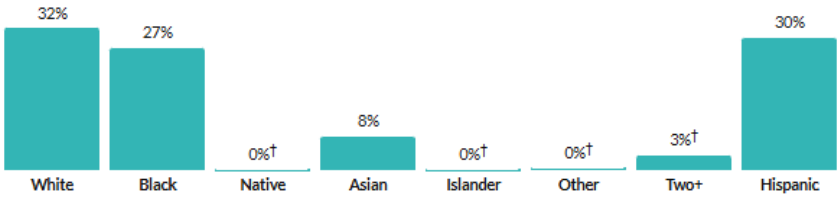


Figura 2 – Distribuição das etnias e raças em Chicago - Fonte: U.S. Census Bureau (2023)

- **Porção da população infantil e idosa abaixo da linha da pobreza:**

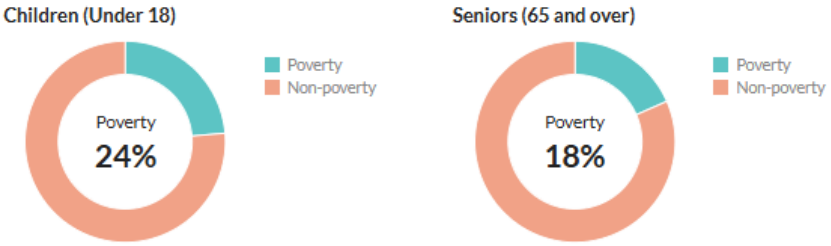


Figura 3 – Índice de pobreza no público infantil e idoso de Chicago - Fonte: U.S. Census Bureau (2023)

1.3.1 Fatores Sociais e Criminais

O estudo de (HWANG; SAMPSON, 2014) observou que Chicago passou por um processo de gentrificação, caracterizado pela transformação socioeconômica e cultural de

determinadas regiões da cidade. Esse processo envolve o aumento gradual do custo de vida, resultando no deslocamento da população original de menor renda e na entrada de grupos com maior poder econômico. Como consequência, a cidade apresenta, até hoje, efeitos significativos desse movimento de reestruturação urbana, tais como o aprofundamento das desigualdades socioespaciais, a intensificação da segregação territorial e a formação de padrões diferenciados de investimento urbano associados a marcadores raciais. Além disso, a gentrificação frequentemente é acompanhada de discursos de "revitalização" que, sob a justificativa de melhoria urbana, promovem o deslocamento sistemático de populações tradicionais, alterando a dinâmica sociocultural e demográfica dos bairros afetados.

1.3.2 Panorama Criminal e Disponibilidade de Dados

A cidade de Chicago constitui um objeto de estudo relevante para pesquisas em segurança urbana, principalmente devido à ampla disponibilidade de dados públicos e à dinâmica criminal característica da região. O Chicago Data Portal (City of Chicago, 2025) disponibiliza um registro com mais de 8 milhões de ocorrências desde 2001, continuamente atualizado, contendo informações essenciais para análise, como o tipo de crime, coordenadas geográficas e horário da ocorrência. Além disso, a cidade apresenta alta volatilidade nos padrões criminais ao longo dos anos, permitindo a comparação da incidência de delitos entre diferentes distritos e a identificação de picos sazonais em determinadas áreas e períodos específicos (Chicago Police Department, 2024). Essa combinação entre grande volume de dados estruturados e variação espaço-temporal significativa torna Chicago um cenário particularmente adequado para estudos de modelagem e previsão de criminalidade.

1.4 Chicago como Laboratório de Inovação em Segurança Pública

Consideradas as situações sociais de Chicago, que possuem um legado de estudo na criminologia por meio da chamada "Escola de Chicago" (SAMPSON, 2012), iniciou-se um grande incentivo à segurança, levando a cidade a ser pioneira no uso de tecnologias para segurança urbana, combinando conceitos da criminologia e ferramentas de análise de dados (CHICAGO, 2013). Portanto, após essa combinação, o departamento de segurança pública de Chicago obteve uma melhor visualização dos crimes que ocorriam em seu

território, por meio da implementação de sistemas de policiamento preditivo e da criação de listas estratégicas de sujeitos (PERRY, 2016). Sendo assim, tornou-se possível criar novas estratégias e otimizar a distribuição de recursos públicos, consolidando a cidade como um verdadeiro laboratório de inovação em segurança pública (CHICAGO, 2013; PERRY, 2016).

1.4.1 Trajetória Histórica

A trajetória de inovação tecnológica na segurança pública de Chicago pode ser segmentada em fases distintas. Durante a década de 1990, houve o pioneirismo na implementação do *CompStat* (Computer Statistics), um sistema que revolucionou a gestão policial ao integrar estatísticas criminais georreferenciadas com princípios de prestação de contas (*accountability*) para uma alocação mais dinâmica de recursos (JANG; HOOVER; JOO, 2010).

Em seguida, na década de 2010 até aproximadamente 2020, a cidade se adaptou para uma abordagem mais proativa, adotando modelos de policiamento preditivo. Sendo assim, esta fase foi marcada pela predição de *hotspots* criminais por meio de algoritmos de aprendizado de máquina, entre os quais se destaca o *Random Forest* (AND, 2018).

Atualmente, pós-2020, observou-se um amadurecimento crítico do uso dessas ferramentas. Em resposta a críticas robustas sobre vieses algorítmicos e questões éticas, houve um movimento crescente, tanto acadêmico quanto institucional, em direção a uma maior transparência e auditoria dos dados e modelos utilizados (LI; GOEL, 2025).

1.4.2 Desafios para Análise Preditiva

Apesar da riqueza do *Chicago Data Portal*, os conjuntos de dados criminais apresentam limitações críticas que podem introduzir vieses significativos em modelos preditivos, conforme discutido na literatura especializada (GRUBESIC; MACK, 2016).

Apesar da riqueza do Chicago Data Portal, os conjuntos de dados criminais apresentam limitações importantes que podem introduzir vieses significativos em modelos preditivos, conforme discutido em (GRUBESIC; MACK, 2016). Um primeiro desafio refere-se à presença de dados ausentes e inconsistências: determinadas categorias de crime,

como golpes cibernéticos (*cyber fraud*), frequentemente não possuem localização geográfica válida, resultando em um volume considerável de registros sem coordenadas (BOIVIN; FELSON, 2022), o que dificulta a análise espacial e a detecção de padrões territoriais. Além disso, há o problema da subnotificação, que afeta principalmente crimes não violentos ou de menor gravidade, como pequenos furtos e danos ao patrimônio, cujas taxas de registro tendem a ser ainda menores em áreas de maior vulnerabilidade socioeconômica, produzindo viés amostral e distorções na representação da distribuição criminal (GRUBESIC; MACK, 2016). Soma-se a isso a questão da agregação espacial adotada por políticas de privacidade, que reportam incidentes no nível de quarteirão ou interseção, em vez de endereços exatos, reduzindo a granularidade das análises e limitando a precisão de estudos que dependem de localização detalhada (City of Chicago, 2024).

2 Justificativa

A segurança pública constitui um dos pilares fundamentais para o desenvolvimento social e urbano. Em grandes centros metropolitanos, como Chicago, onde foram registrados aproximadamente 25.000 crimes violentos em 2023, segundo o Chicago Data Portal, a adoção de métodos computacionais avançados para análise e previsão criminal emerge não apenas como inovação tecnológica, mas como necessidade estratégica. A crescente disponibilidade de dados estruturados e georreferenciados possibilita a aplicação de técnicas de machine learning e deep learning capazes de identificar padrões temporais e espaciais complexos que não seriam facilmente perceptíveis apenas por métodos tradicionais.

A literatura recente demonstra que a integração de abordagens estatísticas temporais (como Prophet e LSTM) com modelos de detecção espacial de padrões (como DBSCAN) pode reduzir o erro preditivo em até 17,6%, aumentando substancialmente a precisão no mapeamento de áreas de risco (WANG et al., 2016). Essa combinação se mostra especialmente relevante diante da natureza multifatorial do fenômeno criminal, o qual envolve simultaneamente dinâmicas urbanas, variações socioeconômicas e distribuição territorial da violência. Além disso, técnicas baseadas em *ensemble learning*, como o *Random Forest*, contribuem para capturar relações não lineares, fornecendo maior interpretabilidade e robustez analítica.

A escolha de Chicago como estudo de caso é justificada pela ampla disponibilidade de dados abertos, atualizados e padronizados, viabilizados pelo Chicago Data Portal, o que garante transparência metodológica, reprodutibilidade e comparabilidade científica (CATLETT et al., 2019). Tal acesso contrasta com o cenário de países como o Brasil, onde bases criminais frequentemente não são públicas, apresentam inconsistências ou baixa granularidade, dificultando a implementação de políticas públicas baseadas em evidências. Ademais, Chicago possui uma complexidade urbana marcada por desigualdades socioespaciais, processos históricos de segregação territorial e dinâmicas de gentrificação que influenciam diretamente os padrões criminais (HWANG; SAMPSON, 2014), tornando o município um laboratório empírico relevante para investigação.

A aplicação de modelos preditivos em segurança pública possui elevado potencial de impacto: possibilita a alocação estratégica de efetivos policiais, o planejamento de ações preventivas em comunidades vulneráveis e a redução da vitimização por meio de

intervenções orientadas por evidências. Contudo, reconhece-se que tais modelos exigem rigor ético, sobretudo para evitar a reprodução de vieses históricos, respeitar a privacidade dos cidadãos e garantir processos contínuos de avaliação crítica e validação empírica (GRUBESIC; MACK, 2016).

Portanto, este estudo se justifica por sua relevância científica, social e operacional, ao propor um framework preditivo replicável, capaz de apoiar políticas públicas mais eficientes e fundamentadas em dados, sem perder de vista os princípios éticos e de governança necessários à sua aplicação.

3 OBJETIVOS

Objetivo geral

O objetivo geral deste trabalho é a construção de uma interface interativa com um modelo preditivo acoplado, que será capaz de identificar padrões e tendências com base nos dados selecionados, além de ferramentas para análises estatísticas, visando proporcionar *insights* que possam auxiliar na tomada de decisão pelas autoridades responsáveis pela segurança pública.

Objetivos específicos

- Efetuar um bom pré-processamento dos dados criminais utilizados;
- Criação de um modelo preditivo eficaz para a identificação de padrões e tendências;
- Desenvolver uma interface interativa que possibilite uma análise estatística, preditiva e geoespacial, com seleção de parâmetros;
- Validação do modelo por meio de métricas e, em seguida, comparação entre as previsões e os dados reais.

4 MATERIAIS E MÉTODOS

4.1 Workflow de Pesquisa

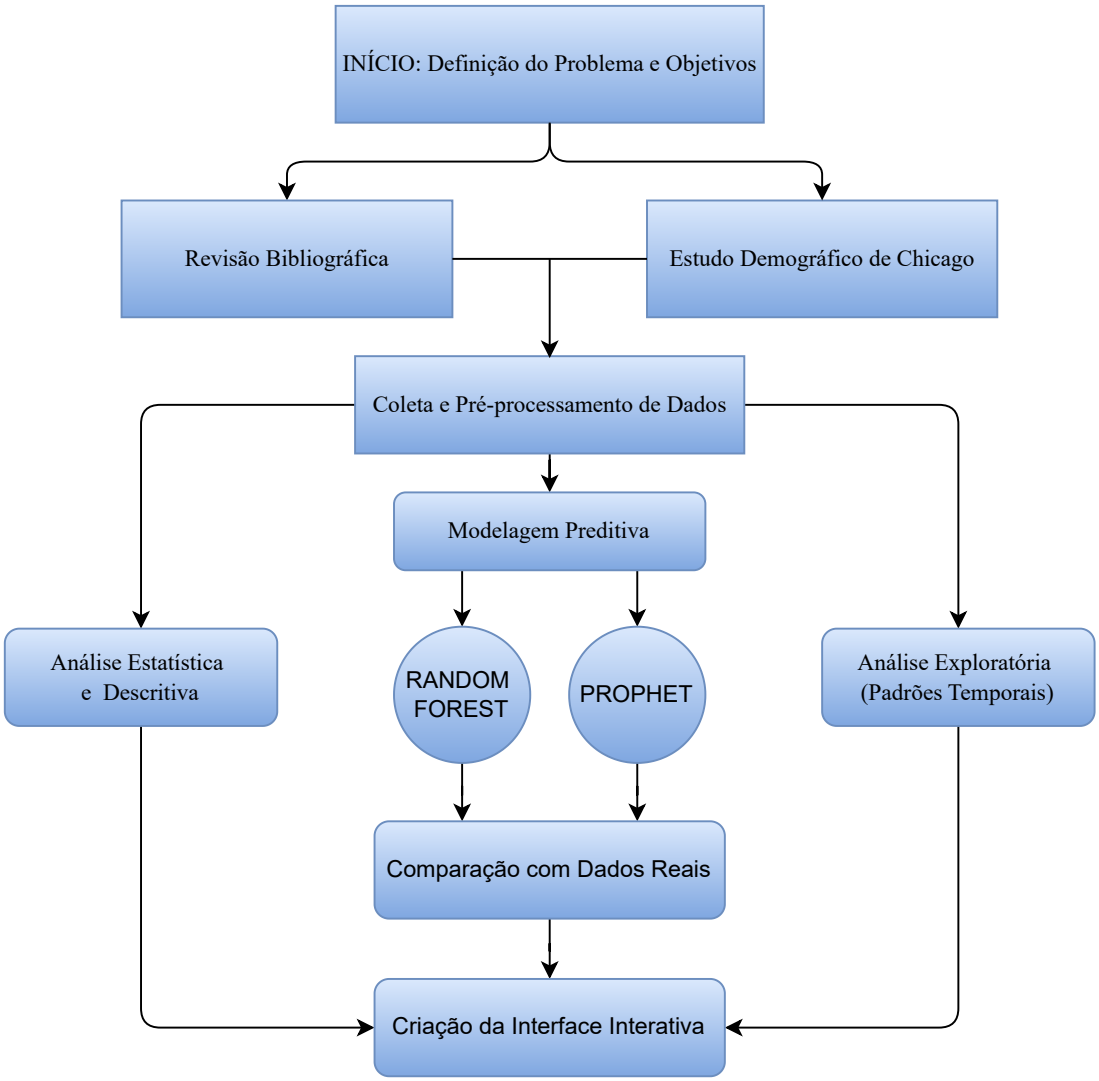


Figura 4 – Fluxo metodológico adotado no desenvolvimento do trabalho. Fonte: próprio autor

Conforme ilustrado na Figura 4, o fluxo metodológico adotado é estruturado em quatro etapas principais: (*i*) definição do problema e revisão bibliográfica; (*ii*) coleta, processamento e análise de dados; (*iii*) modelagem e validação preditiva; e (*iv*) criação do *dashboard* interativo utilizando as ferramentas estudadas.

Inicialmente, realizou-se uma revisão sistemática da literatura sobre inteligência artificial aplicada à segurança pública, com ênfase na análise preditiva da criminalidade.

Esta fundamentação teórica orientou a seleção do estudo de caso, a cidade de Chicago, e a definição da problemática da pesquisa.

Na etapa intermediária, iniciou-se a aquisição do conjunto de dados criminais do Chicago Data Portal (City of Chicago, 2025), seguido de um rigoroso processo de pré-processamento que incluiu a limpeza de valores ausentes, a padronização de formatos, como datas e tipos de crimes, a correção de inconsistências e seleção de atributos relevantes para a modelagem.

Concluído o pré-processamento, realizaram-se as seguintes análises:

4.1.1 Análise Estatística Descritiva

Para a caracterização inicial dos dados, aplicaram-se as seguintes abordagens:

- Análise de Distribuição Temporal: Agregação de ocorrências por horário, dia da semana e mês, utilizando histogramas e séries temporais;
- Análise Espacial: Mapeamento georreferenciado da densidade criminal por meio de *heatmaps* e agrupamento;
- Análise de Frequência: Cálculo de proporções relativas por tipo de crime e avaliação de variações percentuais interanuais;
- Validação de Qualidade: Identificação sistemática de dados ausentes, *outliers* e inconsistências por meio de estatísticas sumárias.

4.1.2 Análise Exploratória de Série Temporal

Para a investigação de padrões temporais, aplicou-se a decomposição clássica de séries temporais, separando os componentes de tendência, sazonalidade e resíduos. A sazonalidade foi analisada em múltiplas granularidades:

- Sazonalidade Anual: Padrões relacionados às variações climáticas sazonais em Chicago;
- Sazonalidade Semanal: Comportamento diferenciado entre dias úteis e finais de semana;
- Autocorrelação: Análise da ACF (*Autocorrelation Function*) para identificar dependências temporais;

- Teste de Estacionariedade: Aplicação do teste *Augmented Dickey-Fuller* para verificar características de estacionariedade.

4.1.3 Modelagem Preditiva

A modelagem seguiu um protocolo estruturado de validação temporal:

- Divisão Temporal: Separação dos dados em conjuntos de treino (80%) e teste (20%), preservando a ordem temporal;
- Validação Cruzada Temporal: Aplicação de *rolling window cross-validation* com janela deslizante de 30 dias;
- Métricas de Avaliação:
  - MAE (Erro Absoluto Médio): $\frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$
  - MSE (Erro Quadrático Médio): $\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$
  - RMSE (Raiz do Erro Quadrático Médio): $\sqrt{\text{MSE}}$
  - MAPE (Erro percentual Quadrático Médio): $\frac{100\%}{n}\sum_{i=1}^{n}\left|\frac{y_i - \hat{y}_i}{y_i}\right|$
- Seleção de Modelos: Comparação de desempenho entre *Prophet* (especializado em sazonalidade) e *Random Forest* (robusto para relações não-lineares).

4.2 Base de Dados

Este trabalho utiliza o conjunto de dados público dos Crimes em Chicago, a partir de 2001 até o presente, disponibilizado pelo *Chicago Data Portal* (City of Chicago, 2025), que é originário do sistema CLEAR (*Citizen Law Enforcement Analysis and Reporting*) do Departamento de Polícia de Chicago.

O conjunto reflete os incidentes criminais registrados na cidade de Chicago a partir de 2001, sendo atualizado periodicamente com a exclusão dos últimos sete dias para garantir a consolidação das informações. Além do mais, para preservar a privacidade das vítimas, os endereços são apresentados apenas em nível de quarteirão, sem identificar locais específicos.

Na versão utilizada neste estudo, a base é composta por mais de 8,4 milhões de registros, cada um representando um incidente criminal reportado, e contém 22 atributos que detalham o crime. Esses atributos incluem informações temporais (data e hora),

geográficas (bloco, distrito policial, coordenadas de latitude e longitude) e descritivas (tipo primário e secundário do crime, descrição, localização exata, se ocorreu em residência, rua, etc., e o status da investigação).

4.3 Pré-processamento de dados e criação dos modelos

4.3.1 Ferramentas e Ambiente Computacional

As análises e modelagens deste trabalho foram implementadas na linguagem de programação Python (versão 3.11.13), utilizando ambientes de desenvolvimento integrado como *Google Colaboratory*⟨https://colab.research.google.com/⟩, *VS Code* ⟨https://code.visualstudio.com/⟩ e a plataforma *Kaggle* ⟨https://www.kaggle.com/⟩. Para o processamento de dados e a implementação dos modelos, foram empregadas as seguintes bibliotecas:

- *Pandas* (versão 2.2.2) e *NumPy* (versão 2.0.2): Utilizadas para manipulação, limpeza, agregação e transformação eficiente do conjunto de dados criminais;
- *Matplotlib* (versão 3.10.0) e *Seaborn* (versão 0.13.2) foram utilizados para a geração de gráficos e visualizações durante a análise exploratória e a apresentação dos resultados;
- *Streamlit* (versão 1.51.0) e *Visual Studio code* (versão 1.105.0) A plataforma Visual Studio code foi utilizada para implementar o *Streamlit* e utilizá-lo como suporte para o funcionamento do *Dashboard*;
- *Scikit-learn* (versão 1.7.2): Biblioteca fundamental para a implementação de algoritmos de Aprendizado de Máquina, incluindo o modelo *Random Forest* e o algoritmo de clusterização DBSCAN;
- *Prophet* (versão 1.1.7): Framework específico para previsão de séries temporais, desenvolvido pelo Meta (*Facebook*), utilizado para modelar tendências e sazonalidades da criminalidade;
- *Darts* (versão 0.38.0): Biblioteca especializada em séries temporais que fornece uma interface unificada para diversos modelos de previsão.

Arquitetura da Biblioteca Darts

A biblioteca *Darts (Unit 8)* foi utilizada como *framework* principal para a modelagem de séries temporais, oferecendo uma arquitetura robusta que implementa as melhores práticas do domínio (HERZEN et al., 2022). Suas principais vantagens incluem:

- Abstração de Séries Temporais: Através da classe `TimeSeries`, que encapsula automaticamente a indexação temporal, o tratamento de datas e a divisão treino/teste temporalmente consciente, prevenindo eficientemente *data leakage*;
- *Interface* Unificada: Os modelos que utilizei do Darts (estatísticos, baseados em árvores ou *deep learning*) seguem a mesma interface para treinamento (`fit()`) e previsão (`predict()`), simplificando significativamente a experimentação e a comparação entre abordagens;
- Validação Temporal Especializada: Implementa métodos específicos para validação cruzada temporal (*backtesting*) com janelas deslizantes, garantindo a avaliação realista dos modelos;
- Métricas Especializadas: Oferece implementações otimizadas de métricas de erro específicas para predição temporal (MAPE, MAE, MSE) que lidam corretamente com a natureza sequencial dos dados.

Justificativa das Escolhas Metodológicas

A seleção do *Prophet* é justificada pela sua capacidade comprovada de capturar padrões sazonais complexos (anuais, semanais e diários) de forma robusta, mesmo na presença de *outliers* e tendências não-lineares. Já a opção pelo *Random Forest* via *Scikit-learn* deveu-se à sua eficácia em lidar com relações não-lineares entre variáveis e à sua resistência ao *overfitting*. Para as análises de clusterização espacial, o algoritmo DBSCAN foi selecionado pela biblioteca *scikit-learn*, devido à sua capacidade de identificar formatos arbitrários de clusters sem requerer a pré-definição do número de agrupamentos, sendo particularmente adequado para a detecção de *hotspots* criminais.

A integração entre essas ferramentas, seguindo as instruções e informações conforme as bibliotecas do *framework Darts* para o *Prophet*, do *Scikit-learn* para o *Random Forest* e DBSCAN, permitiu implementar um *pipeline* completo de análise preditiva temporal, desde

a criação das séries temporais até a avaliação final dos modelos, seguindo rigor metodológico e boas práticas de reprodutibilidade científica. (PEDREGOSA et al., 2011),(HERZEN et al., 2022)

4.3.2 Protocolo de Limpeza e Transformação

Os dados brutos foram submetidos a um processo de limpeza e transformação envolvendo:

- Seleção Temporal: Foco no período de 2014 a 2019 para garantir a consistência metodológica;
- Tratamento de Valores Ausentes: Exclusão de registros sem coordenadas geográficas ou data válida;
- Padronização de Categorias: Unificação de nomenclaturas para tipos de crime e localizações;
- Agregação Temporal: Conversão para frequência diária para análise de séries temporais;
- Exclusão de colunas: Colunas que não agregam às análises preditivas e exploratórias foram excluídas.

4.3.3 Protocolo dos Modelos Preditivos

O protocolo experimental foi baseado em dados do período de 2014 a 2018, seguindo uma divisão temporal em que os anos de 2014 a 2017 (80% do período) foram destinados ao treinamento dos modelos, e o ano de 2018 (20% do período) foi reservado para teste e validação. Esta abordagem preserva a ordem temporal dos dados, simulando um cenário realista de previsão onde modelos são construídos com base no passado para prever comportamentos futuros.

Para capturar padrões sazonais complexos, incorporou-se a influência dos feriados nacionais dos EUA, o que exigiu análise com granularidade diária, de modo que o modelo preditivo avalia dois dias antes e depois da data exata do feriado. O desempenho preditivo foi quantificado por meio das métricas MAE (Erro Absoluto Médio), MSE (Erro Quadrático Médio), RMSE (Raiz do Erro Quadrático Médio) e MAPE (Erro Percentual Absoluto

Médio), seguindo práticas consolidadas na literatura de séries temporais. Por fim, avaliaram-se os gráficos de tendências, o impacto dos feriados e as sazonalidades anuais e semanais.

Tabela 1 – Resumo dos Componentes Temporais Identificados

Componente	**Padrão Identificado**	**Implicações para Segurança Pública**
Tendência	Estabilidade com ajustes pontuais	Necessidade de monitoramento contínuo
Sazonalidade Semanal	Picos nos fins de semana	Alocação estratégica nos fins de semana
Sazonalidade Anual	Máximo no verão, mínimo no inverno	Planejamento sazonal de recursos
Feriados	Variações de até 6%	Protocolos especiais para datas comemorativas

4.4 Construção do Dashboard

O *dashboard* foi desenvolvido na *plataforma Visual Studio Code* (VS code), através da biblioteca *streamlit*. Além disso, é composto por cinco códigos diferentes. O primeiro representa a interface inicial do *dashboard*, indicando as ferramentas disponíveis, enquanto as outras quatro são os códigos para o funcionamento das ferramentas de análise, com quatro tipos de análises diferentes:

- Ferramenta de exploração dos dados, disponibilizando análises estatísticas do banco de dados;
- Análise Estatística: Filtros interativos e visualização tabular;
- Predição de Dados: Modelos preditivos e análise de padrões futuros;
- Análise Geográfica: Mapas de calor e distribuição espacial.

5 RESULTADOS E ANÁLISES

5.1 Contextualização Histórica (2001-2023)

5.1.1 Evolução Temporal de Longo Prazo

Conforme apresentado na figura 5, percebe-se a evolução histórica da criminalidade em Chicago entre 2001 e 2023, revelando quatro fases distintas, com implicações significativas para as políticas de segurança pública.

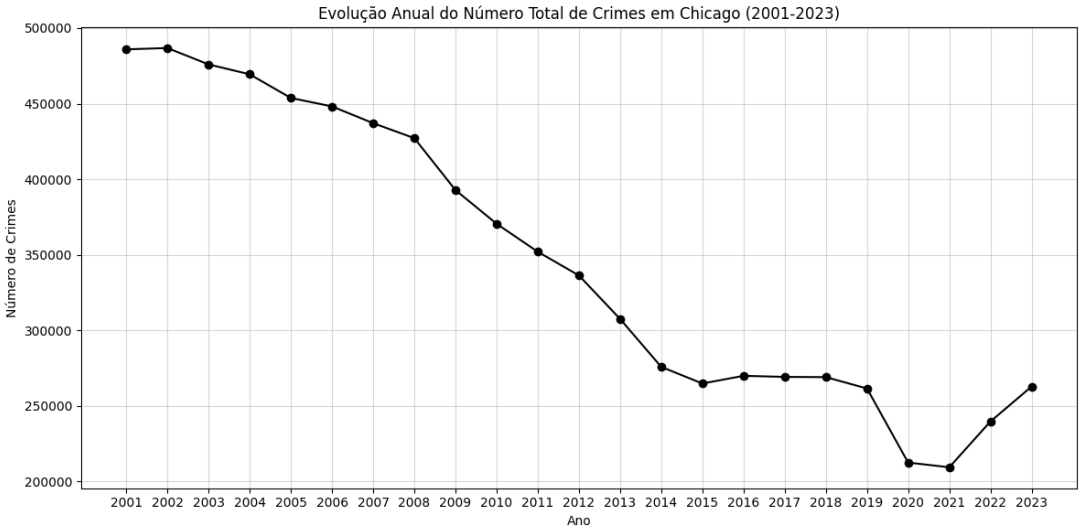


Figura 5 – Evolução anual do número total de crimes em Chicago (2001-2023). Fonte: próprio autor.

- Fase 1: Declínio Acelerado (2001-2004): Queda de aproximadamente 40% no período, impulsionada por políticas de tolerância zero e investimentos em tecnologia policial, além de reformas nos métodos de classificação de ocorrências.
- Fase 2: Estabilização em Patamar Elevado (2005-2013): Estabilização em torno de 350.000 a 400.000 crimes anuais, com flutuações cíclicas que indicavam limitações das estratégias convencionais de segurança.
- Fase 3: Segundo Declínio (2014-2019): Redução consistente de aproximadamente 25% em 5 anos, período que coincide com a adoção de policiamento preditivo e análise de dados.
- Fase 4: Impacto da Pandemia e Recuperação (2020-2023): Queda abrupta de 30% em 2020 devido às restrições da COVID-19, seguida por uma recuperação progressiva que se estabilizou em um patamar historicamente baixo.

5.1.2 Tipos de crimes mais reportados

Conforme ilustrado pela Figura 6, nota-se que os crimes mais reportados em Chicago são predominantemente não letais, com destaque para *Theft* (furto/roubo) e *Battery* (agressão). Estes integram o grupo dos cinco crimes mais frequentes, evidenciando um perfil característico de grandes centros urbanos. Logo, dada essa predominância, as análises preditivas serão concentradas em capturar os padrões comportamentais desses tipos de crimes.

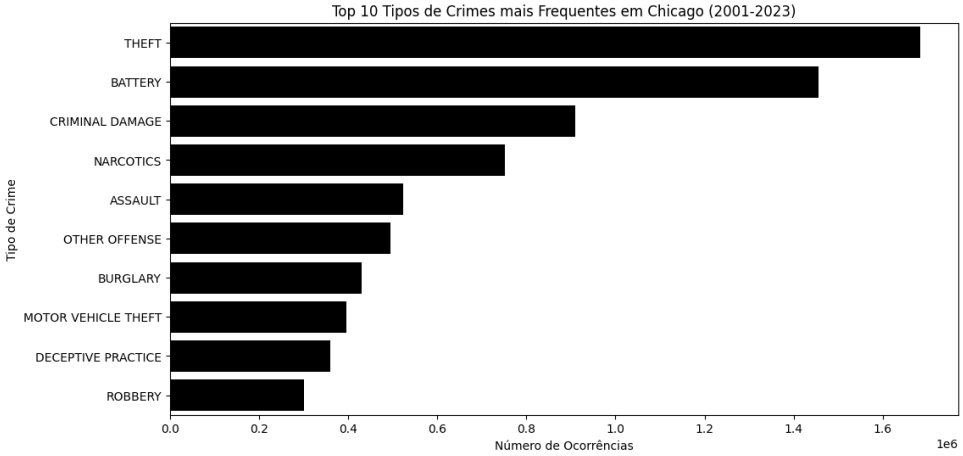


Figura 6 – Representação dos tipos de crimes que foram reportados em Chicago (2001-2023). Fonte: próprio autor.

5.1.3 Análise do horário das ocorrências de Chicago

Conforme ilustrado pela Figura 7, o gráfico da distribuição criminal apresenta um padrão temporal bem definido, com pico noturno entre 18h e 22h e vale matinal entre 4h e 7h. Esse comportamento cíclico reflete diretamente a dinâmica urbana, onde a maior movimentação populacional correlaciona-se com uma elevada incidência delitiva. A tabela a seguir detalha esses períodos característicos, fundamentando a previsibilidade temporal essencial para modelos preditivos de alocação policial.



Figura 7 – Contagem do número de crimes reportados conforme as horas do dia, evidenciando o comportamento urbano de Chicago (2001-2023). Fonte: próprio autor.

Tabela 2 – Padrões Horários de Criminalidade em Chicago (2001-2023)

Período	**Características**	**Intensidade Relativa**
Madrugada (00h-06h)	Vale pronunciado, mínima atividade	25% do pico
Manhã (06h-12h)	Crescimento progressivo	50-75% do pico
Tarde (12h-18h)	Plateau alto, pico às 18h	85-100% do pico
Noite (18h-23h)	Decaimento gradual	70-100% do pico

5.2 Resultados da Análise Exploratória de Série Temporal

A análise exploratória foi realizada no ano de 2014 até 2018, com foco nas ocorrências de assaltos espalhadas pela cidade de Chicago. Sendo assim, percebe-se o comportamento e os padrões dos dados, de modo que a seleção dos modelos preditivos *Prophet* e *Random Forest* foi bem feita e fundamentada.

Diante disso, nota-se que é possível avaliar o comportamento e os padrões de diferentes tipos de crimes em diferentes períodos de tempo, conforme os gráficos apresentados na Figura 8, utilizando a interface do *dashboard*, como revela a Figura 9.

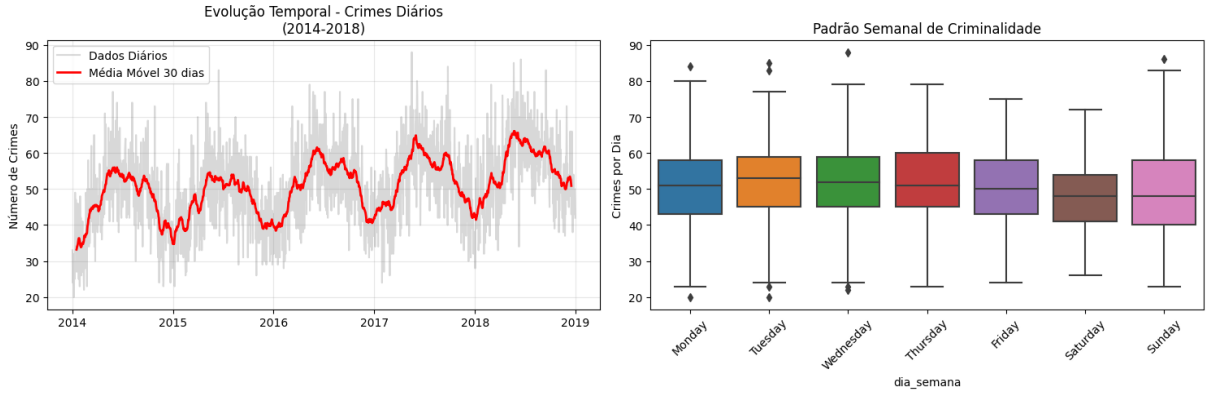


Figura 8 – Apresentação de 2 gráficos sobre análises exploratórias do ano de 2014 até 2018, para as ocorrências de assaltos. Seguindo a ordem da esquerda para a direita, a primeira indica a série original, no caso a distribuição de ocorrências; a segunda demonstra uma análise das ocorrências nos dias da semana, através de *boxplots*. Fonte: próprio autor.

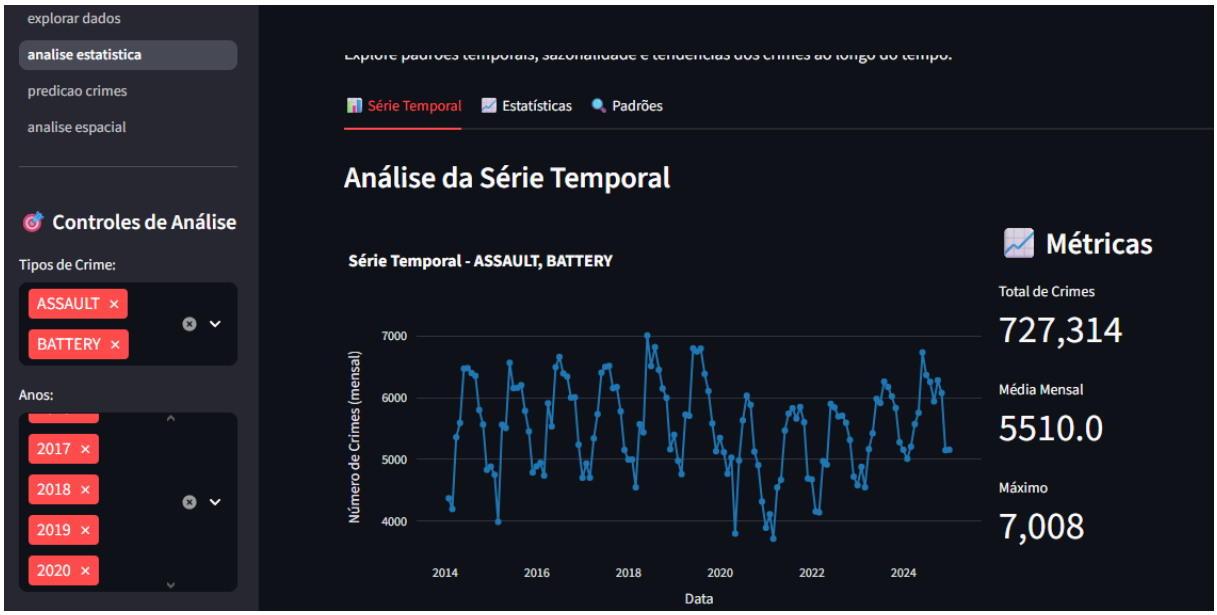
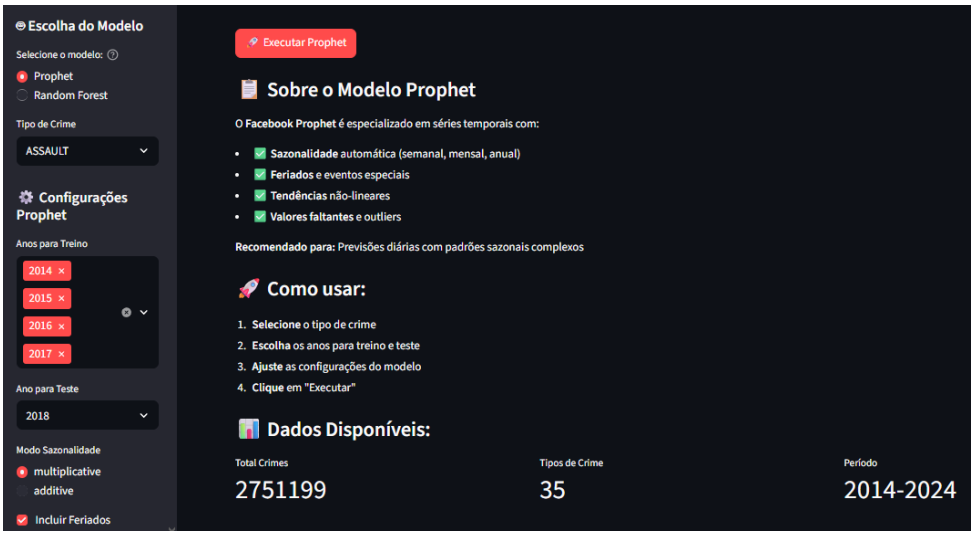


Figura 9 – A imagem representa uma parte do *dashboard* construído, neste caso é a parte de análise estatística e temporal dos dados. Fonte: próprio autor.

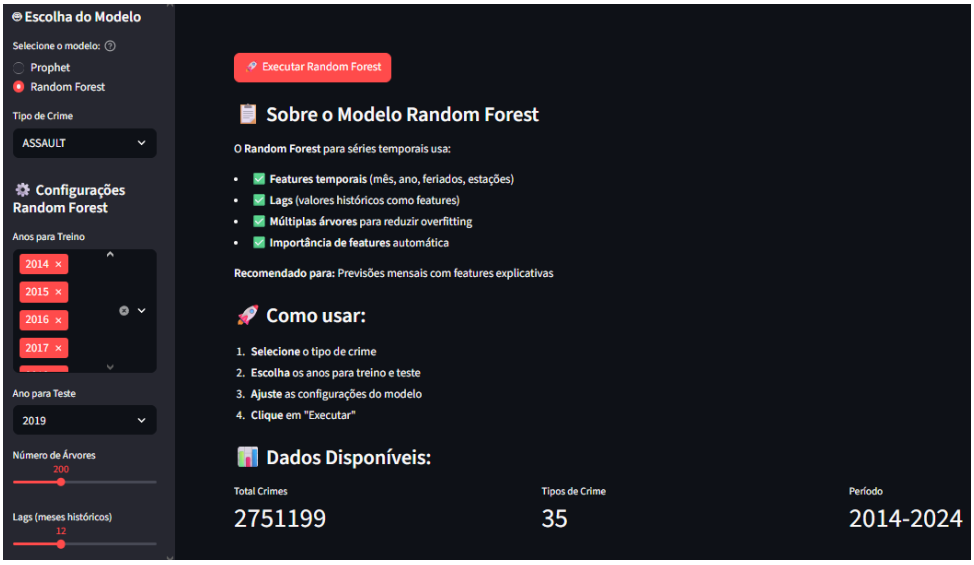
5.3 Análises preditivas obtidas

Portanto, por meio do *dashboard*, como está sendo apresentado na Figura 10, os resultados são baseados nos modelos computacionais *Prophet* (especializado em séries temporais) e *Random Forest* (baseado em *ensemble learning*). Ambos utilizam leves adaptações com feriados para melhorar seu desempenho, pois já se sabe que, durante os feriados, os comportamentos humanos fogem do habitual. Assim, visando diminuir essa influência nas predições, é necessário o uso desse tipo de *feature*. Ademais, a ferramenta

de predição do modelo *Prophet* é capaz de realizar uma análise exploratória dos dados de teste que foram analisados, como apresentado na Figura 11



(A) *Interface* do *Prophet* e seus parâmetros.



(B) *Interface* do *Random Forest* e seus parâmetros.

Figura 10 – Apresentação da *interface* interativa com os modelos preditivos *Random Forest* e *Prophet* Fonte: próprio autor.

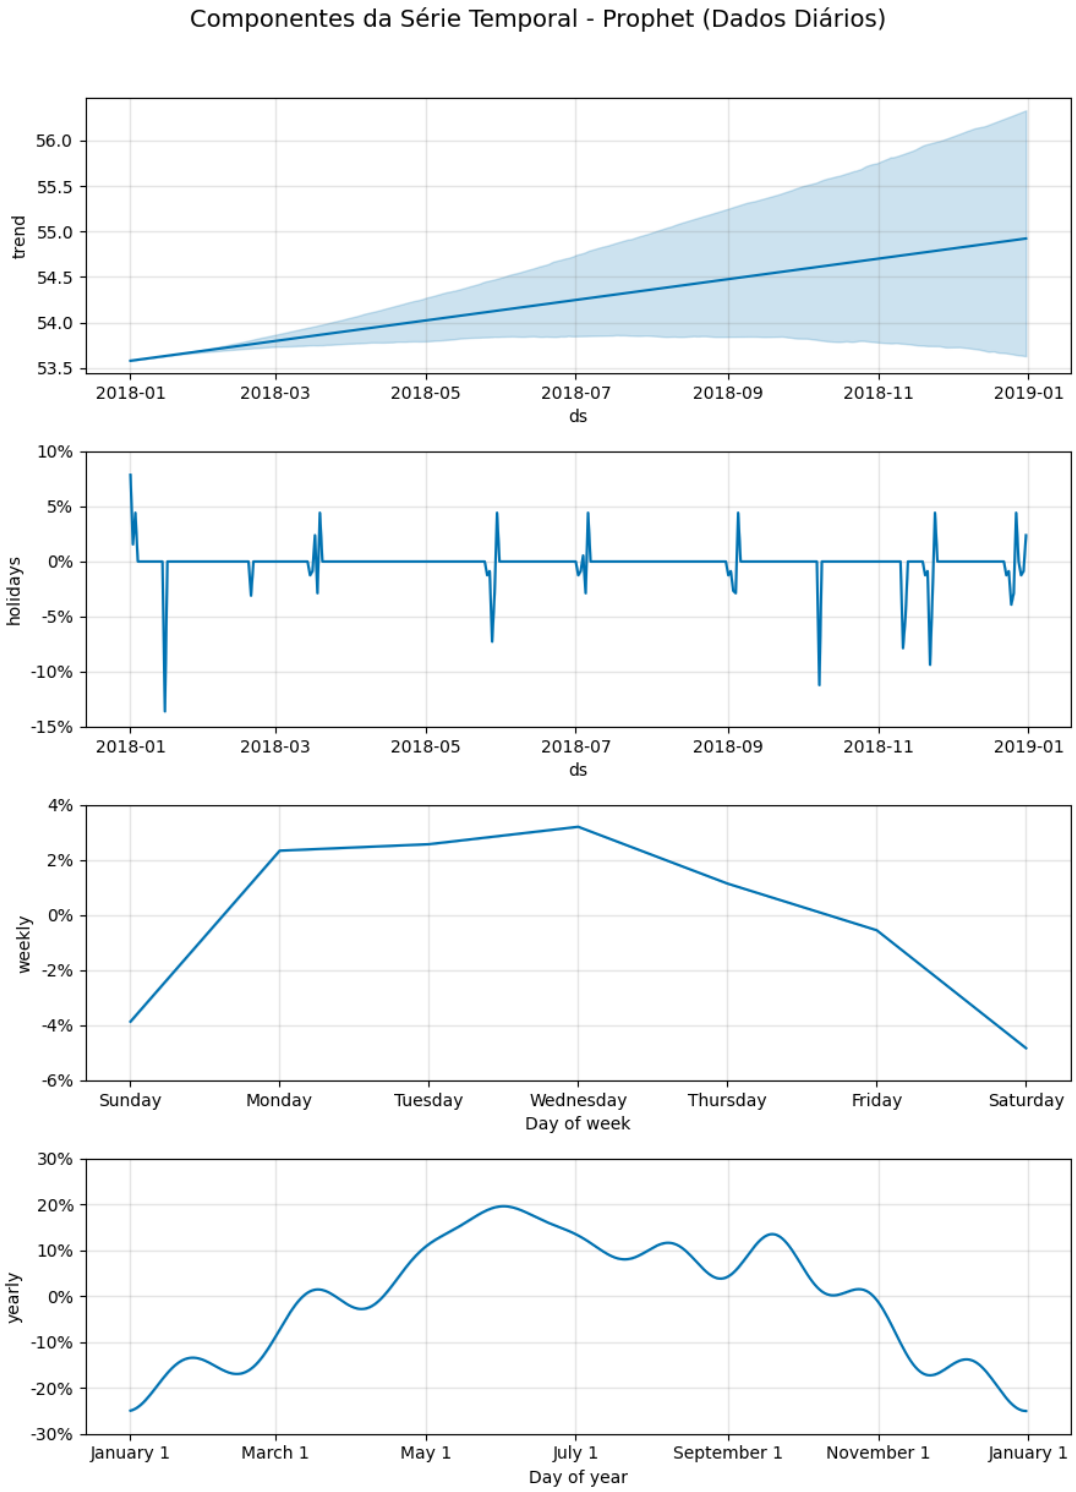


Figura 11 – A figura representa 4 gráficos indicando informações do ano teste (2018). De cima para baixo, a primeira demonstra as tendências dos crimes, no caso é uma tendência crescente; a segunda indica a variação da distribuição de crimes, aumentando ou diminuindo, com a influência dos feriados; a terceira, é uma análise percentual dos crimes conforme os dias; por último, também temos uma análise percentual da distribuição de crimes do dia 1 de Janeiro de 2018 até 1 de Janeiro de 2019. Fonte: próprio autor.

5.4 *Exploração dos dados por meio da localização*

Através do método de clusterização DBSCAN e dos mapas de calor, pode-se observar a distribuição das ocorrências no mapa de Chicago, variando a distância do agrupamento (eps), o número de amostras, o tipo de crime, além do ano e do mês para a análise, conforme demonstrado pela Figura 12, que é um exemplo do modelo utilizado no *dashboard*. Então, essa tecnologia auxiliará o usuário a obter *insights* valiosos, os quais influenciarão nas decisões e medidas a serem tomadas.

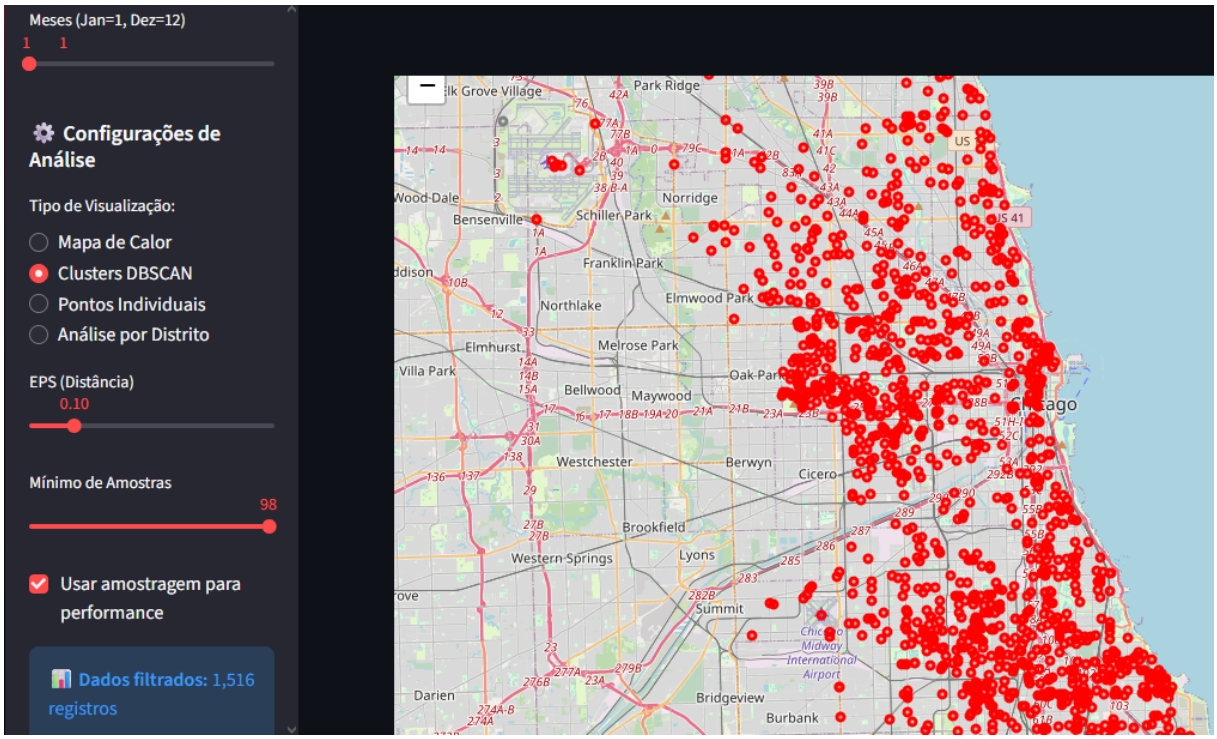


Figura 12 – Imagem representativa do *dashboard* utilizando a ferramente de análise espacial para visualizar *hotspots* e distribuições das ocorrências conforme a localização. Fonte: próprio autor

5.5 *Visualização da interface interativa e os códigos envolvidos*

Portanto, como a Figura 13 demonstra, o *dashboard* foi construído com a finalidade de incorporar as ferramentas de análise estudadas, possibilitando ao usuário a interação e a escolha dos parâmetros e filtros. Desse modo, o usuário possui uma vasta opção de seleções, criando diversas análises possíveis para diferentes situações que desejar.

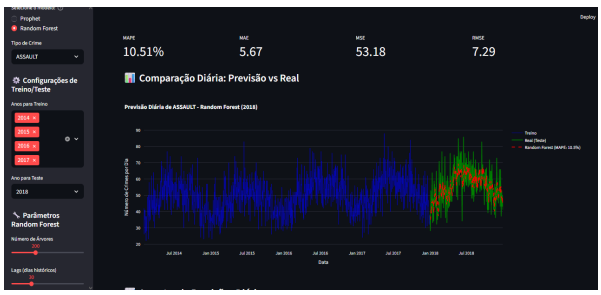


Figura 13 – *Interface* inicial do *dashboard*, representando as 4 ferramentas de análise. Fonte: próprio autor

5.6 Comparação do modelo Random Forest e Prophet

No contexto de segurança pública, ambos os modelos oferecem contribuições complementares, permitindo diferentes abordagens para a tomada de decisão estratégica baseada em dados. Diante disso, vamos comparar o desempenho dos modelos preditivos para a mesma situação, neste caso:

- Tipo de crime: Assalto;
- Período de análise: 2014 a 2018;
- Treino: 2014 até 2017 (80%);
- Teste: 2018 (20%).
- Avaliação dos resultados com as métricas MAPE, MAE, MSE e RMSE;



(a) Random Forest (MAPE: 10,51%)



(b) Prophet (MAPE: 12,27%)

Figura 14 – Comparação do desempenho preditivo entre Random Forest e Prophet para crimes de assalto em Chicago (2014-2018). Fonte: próprio autor.

Tabela 3 – Desempenho comparativo dos modelos preditivos

Métrica	*Prophet*	*Random Forest*
MAPE	12,27%	**10,51%**
MAE	6,68	**5,67**
MSE	73,26	**53,18**
RMSE	8,56	**7,29**

Conforme apresentado na Figura 14, a análise comparativa entre os modelos *Prophet* e *Random Forest* revela desempenhos semelhantes: o ***Random Forest*** destaca-se pelo menor erro percentual (MAPE de 10,51%), enquanto o ***Prophet*** apresentou um erro percentual (MAPE de 12,27%), além das outras métricas avaliadas, como MAE, MSE, e RMSE, conforme evidenciado na Tabela 3.

A diferença de desempenho reflete os propósitos distintos dos algoritmos: o *Random Forest* demonstra superioridade na captura de relações não-lineares complexas presentes nos dados criminais, enquanto o *Prophet*, embora especializado em séries temporais, mostrou-se menos adaptável aos padrões dinâmicos e não-lineares da criminalidade urbana

5.6.1 Comparação em situações atípicas

Para melhor avaliar ambos os modelos, testou-se a predição em um período totalmente atípico, que foi a pandemia de Covid-19 registrada de 2019 até meados de 2021, aproximadamente. Na seguinte situação, houve a quebra de padrão e o treinamento dos modelos com dados em transição de comportamento (treino com dados já na pandemia).



Figura 15 – Resultados da predição de crimes de furto, com o modelo *Prophet*, durante a pandemia da Covid 19. Dados de treino de 2017 a 2020, e ano de teste 2021. Fonte: próprio autor.

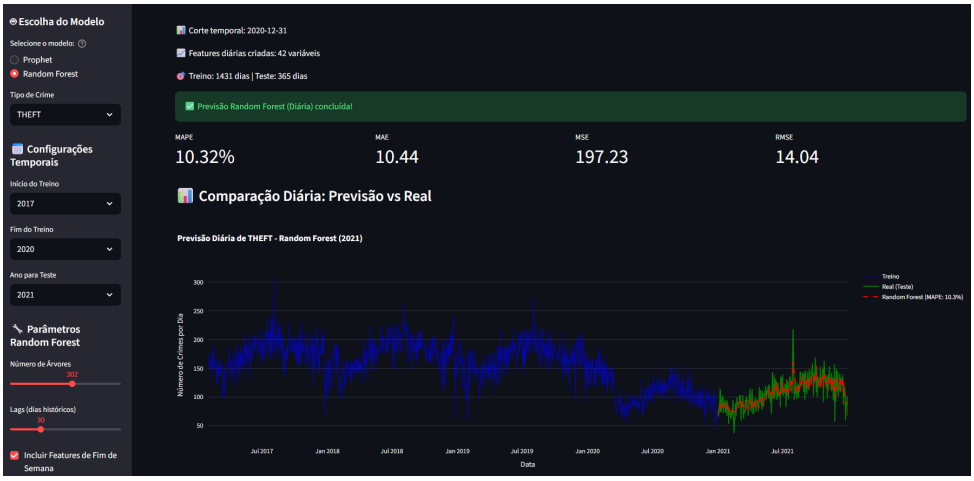


Figura 16 – Resultados da predição de crimes de furto, com o modelo *Random Forest*, durante a pandemia da Covid 19. Dados de treino de 2017 a 2020, e ano de teste 2021. Fonte: próprio autor.

Tabela 4 – Desempenho comparativo dos modelos preditivos em situação atípica

Métrica	**Prophet**	**Random Forest**
MAPE	54,44%	**10.32%**
MAE	62,86	**10,44**
MSE	5173,42	**197,23**
RMSE	71,93	**14,04**

Diante das Figuras 15 e 16 e da Tabela 4, nota-se, através dos gráficos e métricas, a fragilidade do modelo preditivo *Prophet* em situações com fortes mudanças de padrões inesperados, uma vez que modelos baseados em padrões sazonais históricos têm grandes chances de falhar quando esses padrões são quebrados por eventos disruptivos. Além disso, o *Prophet* está habituado a tendências suaves e a sazonalidades estáveis ao longo do tempo, o que não ocorreu durante o período de *lockdown*. Portanto, reafirma-se que o modelo *Random Forest* manteve seu desempenho, pois é um modelo mais flexível a mudanças de comportamento.

5.7 DISCUSSÃO

5.7.1 Avaliação da interface interativa

Portanto, observamos as funcionalidades da inteligência artificial e da análise de dados no contexto da segurança pública. Além disso, foi possível integrar essas ferramentas em um *dashboard* interativo, tornando-o uma tecnologia útil, acessível e capaz de auxiliar na tomada de decisões.

Diante disso, notou-se que os resultados obtidos pelas previsões foram satisfatórios, uma vez que as métricas utilizadas em ambos os modelos, nas condições que empregamos, estavam dentro do esperado. Na primeira predição dos modelos, ambos apresentaram desempenho equivalente; no caso o modelo *Random Forest* obteve um MAPE de 10,51%, enquanto o *Prophet* obteve 12,27%, classificando-os como bons modelos preditivos, segundo parâmetros estabelecidos na literatura (HYNDMAN; KOEHLER, 2006). Por outro lado, ao avaliarmos os modelos em uma situação com quebra de sazonalidade e tendências, nota-se algumas características dos modelos, que são a maior flexibilidade por parte do *Random Forest* e a melhor adaptação para padrões repetitivos bem definidos por parte do *Prophet*, além da influência dos dados de treino para ambos os modelos se adaptarem.

Além disso, vale ressaltar que, para uma boa análise dos dados, é essencial um bom pré-processamento dos dados selecionados, para que se evitem falsas interpretações ou incoerências. Esta etapa mostrou-se crucial para a qualidade dos resultados obtidos.

5.7.2 Limitações do estudo

Por fim, em relação aos desafios encontrados no estudo, há alguns pontos relevantes para refletirmos. no caso, são os possíveis erros mecânicos e humanos no momento de registrar a ocorrência e encaminhá-la ao banco de dados, evidenciando a ideia de que bancos de dados mal construídos ocasionam treinamento de modelos preditivos ruins. Além disso, as localizações são aproximadas para impedir a exposição de dados das vítimas. Vale ressaltar que o banco de dados não revela o número real de crimes que ocorrem, e sim o número de crimes reportados.

6 CONCLUSÃO

Ao final deste trabalho, percebeu-se que é possível integrar ferramentas computacionais avançadas para a interpretação e predição de dados criminais, incorporando-as em um *dashboard* interativo que auxilia na visualização e na tomada de decisões no contexto da segurança pública. Além disso, as ferramentas disponibilizadas na interface interativa demonstraram ser eficazes para a exploração e análise dos padrões comportamentais presentes no banco de dados estudado.

Do ponto de vista preditivo, ambos os modelos testados mostraram-se adequados para a análise criminal, desde que levem em consideração as situações em que estão inseridos. Uma vez que, como demonstrado anteriormente, tanto o *Random Forest* quanto o *Prophet* apresentaram excelente desempenho, atingindo um MAPE de 10,51% e um MAPE de 12,27%, respectivamente, validando a aplicabilidade de técnicas de inteligência artificial na previsão de tendências criminais. No entanto, caso sejam inseridas em ambientes nos quais o modelo não é apropriado, percebe-se que o desempenho das predições cai rapidamente, reforçando a necessidade de cuidado na aplicação do modelo e de conhecimento do comportamento dos dados a serem utilizados.

Portanto, os resultados encontrados reforçam que as funcionalidades da IA e a análise de dados são cada vez mais essenciais no cenário contemporâneo, particularmente na segurança pública. A capacidade de prever padrões e comportamentos mostra-se valiosa não apenas neste domínio, mas também nos setores econômico e social, onde a antecipação de tendências pode orientar políticas públicas e a alocação estratégica de recursos.

Além disso, para aperfeiçoamentos futuros, é possível buscar o desenvolvimento de modelos computacionais mais sofisticados, a incorporação de variáveis socioeconômicas adicionais, a expansão da análise para outros tipos de crimes e a aplicação do *framework* desenvolvido em diferentes contextos urbanos. Adicionalmente, deve-se manter a contínua avaliação dos aspectos éticos e do viés algorítmico, garantindo que o uso preditivo na segurança pública seja transparente e equitativo.

Por fim, ampliando a área de utilização dessa metodologia, pode-se aplicá-la a bancos de dados de outras áreas também, como o estudo da distribuição de casos clínicos em hospitais, podendo-se analisar quais comorbidades estão mais presentes e prever ocorrências com base no comportamento das séries temporais.

Referências[1]

AGRESTI, A. *An Introduction to Categorical Data Analysis*. 3rd. ed. Hoboken, NJ, USA: Wiley, 2018. ISBN 978-1119405269. Citado na página 18.

AKBULUT, Y. et al. A review on computer vision techniques for forensic investigation. *Journal of Forensic Sciences*, v. 63, n. 5, p. 1346–1357, 2018. Citado na página 14.

AND, B. J. J. Predictable policing: Predictive crime mapping and geographies of policing and race. *Annals of the American Association of Geographers*, Taylor & Francis, v. 108, n. 1, p. 1–16, 2018. Disponível em: ⟨https://doi.org/10.1080/24694452.2017.1293500⟩. Citado na página 23.

BACHNER, J. *Predictive Policing: Preventing Crime with Data and Analytics*. IBM Center for The Business of Government, 2013. Disponível em: ⟨https://www.businessofgovernment.org/report/predictive-policing-preventing-crime-data-and-analytics⟩. Citado na página 14.

BOIVIN, R.; FELSON, M. Missing data in crime analysis: Patterns, mechanisms, and implications. *Crime Science*, v. 11, n. 1, p. 1–14, 2022. Analisa padrões de dados missing em datasets criminais, incluindo a falta de geolocalização para certos tipos de crime. Citado na página 24.

BUONANNO, P. The socioeconomic determinants of crime. a review of the literature. 12 2003. Citado na página 20.

BURNEY, I.; PEMBERTON, N. Making space for criminalistics: Hans gross and fin-de-siècle csi. *Studies in History and Philosophy of Science Part C: Studies in History and Philosophy of Biological and Biomedical Sciences*, v. 44, n. 1, p. 16–25, 2013. ISSN 1369-8486. Special Issue: Forensic Cultures. Disponível em: ⟨https://www.sciencedirect.com/science/article/pii/S1369848612000969⟩. Citado na página 13.

BUTT, U. M. et al. Spatio-temporal crime hotspot detection and prediction: A systematic literature review. *IEEE Access*, v. 8, p. 166553–166574, 2020. Citado na página 15.

CATLETT, C. et al. Spatio-temporal crime predictions in smart cities: A data-driven approach and experiments. *Pervasive and Mobile Computing*, v. 53, p. 62–74, 2019. ISSN 1574-1192. Disponível em: ⟨https://www.sciencedirect.com/science/article/pii/S157411921830542X⟩. Citado 2 vezes nas páginas 16 e 25.

CHAINEY, S.; TOMPSON, L.; UHLIG, S. The utility of hotspot mapping for predicting spatial patterns of crime. *Security Journal*, v. 21, p. 4–28, 02 2008. Citado na página 19.

CHICAGO, C. of. *Technology and Innovation Plan for Policing*. [S.l.], 2013. Disponível em: ⟨https://www.chicago.gov/content/dam/city/depts/mayor/Press%20Room/Press%20Releases/2013/December/12.18.13TechnologyPlanPolicing.pdf⟩. Citado 2 vezes nas páginas 22 e 23.

[1] De acordo com a Associação Brasileira de Normas Técnicas. NBR 6023.

Chicago Police Department. *Annual Report 2023*. 2024. Disponível em: ⟨https://www.chicagopolice.org/statistics-data/statistical-reports/annual-reports/⟩. Citado na página 22.

City of Chicago. *Data Policy and Privacy – Chicago Data Portal*. 2024. Descreve as políticas de agregação e anonimização de dados para proteger a privacidade, explicando a precisão da geolocalização. Disponível em: ⟨https://www.chicago.gov/city/en/depts/doit/provdrs/open_data/svcs/open-data-portal-data-policies.html⟩. Citado na página 24.

City of Chicago. *Crimes - 2001 to Present*. 2025. Acesso em: 10 abril 2025. Disponível em: ⟨https://data.cityofchicago.org/Public-Safety/Crimes-2001-to-Present/ijzp-q8t2/about_data⟩. Citado 3 vezes nas páginas 22, 29 e 30.

DE, S.; KAUR, M.; BEHERA, R. Crime rate analysis and prediction in delhi using facebook prophet. In: _____. [S.l.: s.n.], 2022. p. 419–428. ISBN 978-981-16-9704-3. Citado na página 17.

DICKEY, D. A.; AND, W. A. F. Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, ASA Website, v. 74, n. 366a, p. 427–431, 1979. Disponível em: ⟨https://doi.org/10.1080/01621459.1979.10482531⟩. Citado na página 16.

ESTER, M. et al. A density-based algorithm for discovering clusters in large spatial databases with noise. In: AAAI PRESS. *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining*. [S.l.], 1996. p. 226–231. Citado na página 19.

ESTER, M.; SANDER, J.; XU, X. A density-based algorithm for discovering clusters in large spatial databases with noise. In: . [S.l.: s.n.], 1996. v. 96, p. 226–231. Citado na página 19.

FENG, M. et al. Big data analytics and mining for effective visualization and trends forecasting of crime data. *IEEE Access*, PP, p. 1–1, 07 2019. Citado na página 18.

GARLAND, D. *La cultura del control: crimen y orden social en la sociedad contemporánea*. [S.l.]: Gedisa, 2012. Citado na página 14.

GORR, W.; OLLIGSCHLAEGER, A.; THOMPSON, Y. Short-term forecasting of crime. *International Journal of Forecasting*, Elsevier, v. 19, n. 4, p. 579–594, 2003. Citado na página 16.

GRUBESIC, T. H.; MACK, E. A. The digital divide and the criminal justice system: A problem of data quality. *Journal of Quantitative Criminology*, v. 32, n. 4, p. 589–607, 2016. Discute vieses e problemas de qualidade em dados criminais digitais, incluindo subnotificação e agregação espacial. Citado 3 vezes nas páginas 23, 24 e 26.

HERZEN, J. et al. Darts: User-friendly modern machine learning for time series. *Journal of Machine Learning Research*, v. 23, n. 124, p. 1–6, 2022. Disponível em: ⟨http://jmlr.org/papers/v23/21-1177.html⟩. Citado 2 vezes nas páginas 32 e 33.

HWANG, J.; SAMPSON, R. J. Divergent pathways of gentrification: Racial inequality and the social order of renewal in chicago neighborhoods. *American Sociological Review*, v. 79, n. 4, p. 726–751, 2014. Disponível em: ⟨https://doi.org/10.1177/0003122414535774⟩. Citado 2 vezes nas páginas 21 e 25.

HYNDMAN, R. J.; KOEHLER, A. B. Another look at measures of forecast accuracy. *International Journal of Forecasting*, v. 22, n. 4, p. 679–688, 2006. ISSN 0169-2070. Disponível em: ⟨https://www.sciencedirect.com/science/article/pii/S0169207006000239⟩. Citado na página 45.

JANG, H.; HOOVER, L. T.; JOO, H.-J. An evaluation of compstat's effect on crime: The fort worth experience. *Police Quarterly*, v. 13, n. 4, p. 387–412, 2010. Disponível em: ⟨https://doi.org/10.1177/1098611110384085⟩. Citado na página 23.

LI, Y.; GOEL, S. Artificial intelligence auditability and auditor readiness for auditing artificial intelligence systems. *International Journal of Accounting Information Systems*, v. 56, p. 100739, 2025. ISSN 1467-0895. Disponível em: ⟨https://www.sciencedirect.com/science/article/pii/S1467089525000156⟩. Citado na página 23.

MANDALAPU, V. et al. Crime prediction using machine learning and deep learning: A systematic review and future directions. *IEEE Access*, v. 11, p. 60153–60170, 2023. Citado na página 15.

PEDREGOSA, F. et al. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011. Citado na página 33.

PERRY, W. L. Research Report, *Predictive Policing in Chicago: An Evaluation of the Strategic Subject List*. 2016. Citado na página 23.

PERRY, W. L. et al. Predictive policing: The role of crime forecasting in law enforcement operations. RAND Corporation, 2013. Disponível em: ⟨https://www.rand.org/pubs/research_reports/RR233.html⟩. Citado na página 14.

SAFAT, W.; ASGHAR, S.; GILLANI, S. A. Empirical analysis for crime prediction and forecasting using machine learning and deep learning techniques. *IEEE Access*, v. 9, p. 70080–70094, 2021. Citado na página 15.

SAMPSON, R. J. The great american city: Chicago and the enduring neighborhood effect. *Social Forces*, v. 91, n. 1, p. 1–10, 2012. Citado na página 22.

SHMATKO, I. Ferguson, andrew guthrie, the rise of big data policing: Surveillance, race, and the future of law enforcement. *Canadian Journal of Sociology*, v. 45, p. 201–204, 06 2020. Citado na página 14.

WANG, H. et al. Crime rate inference with big data. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. New York, NY, USA: Association for Computing Machinery, 2016. (KDD '16), p. 635–644. ISBN 9781450342322. Disponível em: ⟨https://doi.org/10.1145/2939672.2939736⟩. Citado 4 vezes nas páginas 16, 17, 19 e 25.